Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université IBN ZOHR -Agadir
Faculté des Sciences
Centre d'Excellence

Spécialité : Analytique de données et Intelligence Artificielle (ISII)
Module : Informatique Décisionnelle

Modélisation et Optimisation des Systèmes de Gestion des Ventes et Livraison

Encadré par :
Prof.Ait Lahcen Yassin

Réalisé par :
AGCHAR RABIAA
ASSRAOUI OUSSAMA

Année Universitaire : 2025 – 2026

Table des matières

1 Identification de la table de faits et des mesures 6

2 Identification des dimensions 7

3 Schéma en étoile 7

4 Définition des métadonnées 9

5 Présentation globale du processus ETL 14

6 Technologies utilisées 14

7 Présentation des données sources 17

8 Préparation des données sources 17
8.1 Transformation des données . . . 19
8.2 Construction de dimension du temps . . . 25
8.3 Chargement dans l'entrepôt de données . . . 27
8.3.1 Processus détaillé : . . . 27
8.3.2 Transformations et Configuration . . . 33
8.3.3 Processus détaillé . . . 33

Introduction 38

9 Technologies utilisées 38
9.1 Visual Studio . . . 38
9.2 SQL Server Analysis Services (SSAS) . . . 39

10 Création du cube OLAP 39
10.1 Création du projet Analysis Services . . . 39

11 Déploiement et traitement du cube OLAP 43
11.1 Configuration du déploiement . . . 43
11.2 Traitement du cube OLAP . . . 43

Conclusion 44

12 Technologies Utilisées 45

13 Chargement des Données dans Power BI 46

14 Visualisation graphique 48

15 Description des données 51

16 Prétraitement 51

17 Méthodologie **51**
17.1 Outil WEKA 51
17.2 Algorithme K-means 51
17.3 Algorithme Apriori 53

18 Résultats et Analyse **54**
18.1 Résultats obtenus 54
18.2 Interprétation 54

Table des figures

1 Modèle en étoile de Gestion des Commandes et livraison 8
2 table de faits Gestion des Commandes et livraison 9
3 dim Temps 10
4 dim Client 11
5 dim produit 12
6 Vue globale du processus ETL 14
7 Talend Open Studio 15
8 SQL Server 16
9 fichier orders.csv 17
10 job JCommandes créé avec succès 18
11 fichier délimité créé avec succés. 18
12 Visualisation des données extraites dans la console. 18
13 Composant TMap connecté avec succès. 19
14 Configurations tmap. 20
15 Connexion au bd ComptoirDB. 21
16 Connexion des composants tDBOutput avec tMap. 22
17 Configuration des tDBOutput pour la création des tables. 22
18 Execution de job avec succés.. 22
19 Chargement des tables dans la base de données. 23
20 récupération de schéma. 24
21 création dim$_{C}lient$ 24
22 création dim$_{P}roduit$. 24
23 mappage dim client 25
24 mappage dim produit 25
25 mappage dim produit 25
26 générer des dates 26
27 création du variable contexte 26
28 générer des dates 26
29 mappage dim Temps 27
30 Base de données ComptoirDWH 27
31 connexion au Base de données ComptoirDWH 28
32 Connexion de composant tDBOutput avec le tMap. 29
33 Configuration de tDBOutput pour la création de table de faits. 29
34 Exécution de job avec succés.. 30
35 Chargement des tables avec succès 30
36 creation du job jtable fait 31
37 Récupération du shèma 32
38 Intégration des composants dans job 33
39 Génération des clés étrangères. 34
40 Mappage des clés et les mesures 34
41 Mappage des clés et les mesures 35

42 Configuration de tDBOutput pour la création de table de faits. 35
43 Exécution de job avec succés. 36
44 Chargement de la table de fait dans l'entrepôt de données. 36
45 Schèma Conceptuel. 37
46 Environnement de développement Visual Studio 38
47 Microsoft SQL Server Analysis Services 39
48 Création du projet BI *Ventes_Cube* 39
49 Création de la source de données SQL Server 40
50 Création de la Data Source View 41
51 Cube OLAP 42
52 Structure du cube OLAP 42
53 Configuration du déploiement du cube 43
54 Résultat du déploiement 43
55 Traitement du cube OLAP 44
56 Power BI 45
57 Connexion au Power BI 46
58 Récuperation des données 47
59 Analyses et visualisations des résultats 48
60 Dataset chargé dans WEKA 51
61 Configuration de l'algorithme K-means 52
62 Règles d'association générées par Apriori dans WEKA 53
63 Résultats du clustering sous WEKA 54

INTRODUCTION GÉNÉRALE

Dans le cadre de ce projet, nous nous intéressons à l'exploitation de la base de données ComptoirDB, qui représente une base transactionnelle inspirée d'un système de gestion commerciale. Cette base contient des informations relatives aux clients, aux commandes, aux produits, aux ventes ainsi qu'aux délais de livraison et de préparation. Elle constitue un terrain d'étude pertinent pour la mise en œuvre d'une solution décisionnelle complète.

L'objectif principal de ce projet est de concevoir et de mettre en place une architecture BI et Data Mining permettant d'analyser les performances commerciales de l'entreprise. Pour cela, les données de la base ComptoirDB sont extraites, transformées et chargées dans un entrepôt de données, puis organisées selon un modèle multidimensionnel adapté à l'analyse décisionnelle. Des indicateurs clés, tels que le montant des ventes, les délais de livraison, les retards et la performance des clients, sont ensuite analysés à l'aide d'outils OLAP et de techniques de Data Mining.

Ce projet vise également à démontrer l'apport du Data Mining dans la prise de décision, en appliquant des algorithmes de classification et d'analyse afin de dégager des tendances, d'identifier des comportements clients et d'évaluer les facteurs influençant les retards de livraison ou la performance commerciale.

Modélisation Multidimensionnelle

Introduction

Dans une démarche d'informatique décisionnelle, la modélisation constitue une étape clé pour structurer les données et répondre aux besoins d'analyse et d'aide à la décision.

Dans le cadre du projet **BI & Data Mining** basé sur la base **Comptoir DB**, l'objectif est de concevoir un entrepôt de données permettant l'analyse des ventes, des délais de livraison et des comportements d'achat.

Ce chapitre présente la **modélisation multidimensionnelle** adoptée, basée sur l'identification des faits et des dimensions, la conception d'un schéma en étoile et la définition des métadonnées nécessaires aux analyses décisionnelles et aux techniques de **Data Mining**.

1 Identification de la table de faits et des mesures

La table de faits constitue l'élément central du modèle décisionnel. Elle regroupe les événements mesurables issus de l'activité commerciale, accompagnés d'indicateurs chiffrés essentiels à l'analyse et à l'aide à la décision. Dans le cadre du projet **Comptoir DB**, ces événements sont principalement liés aux opérations de vente et aux processus logistiques associés.

Fait principal : Ventes et livraison des commandes

La table de faits retenue modélise les transactions de vente réalisées par l'entreprise, en intégrant les informations relatives aux délais et aux performances de livraison.

Mesures retenues :

- **Montant des ventes** : représente la valeur brute des ventes réalisées. Cette mesure permet d'analyser le chiffre d'affaires selon différentes dimensions telles que le temps, les clients ou les produits.
- **Montant net** : correspond au montant réel après déductions éventuelles. Il permet d'évaluer la rentabilité des ventes et d'effectuer des comparaisons précises entre périodes ou segments de clientèle.
- **Délai de livraison (jours)** : mesure le temps écoulé entre la date de commande et la date de livraison. Cet indicateur est essentiel pour analyser la performance logistique.
- **Délai de préparation (jours)** : représente le temps nécessaire à la préparation des commandes avant expédition. Il permet d'identifier les goulots d'étranglement internes.
- **Délai de Transport (jours)** : correspond à la durée d'acheminement des produits vers le client, utile pour évaluer l'efficacité des moyens de transport.

— **Retard de livraison (jours)** : indique l'écart entre la date de livraison prévue et la date réelle. Cette mesure est particulièrement importante pour les analyses de satisfaction client et pour les algorithmes de Data Mining, notamment le clustering des clients selon les retards.

Pertinence des mesures :

Les mesures retenues ont été choisies pour répondre aux besoins d'analyse décisionnelle et offrir une vision globale des performances commerciales et logistiques. Le montant des ventes et le montant net permettent d'analyser l'évolution du chiffre d'affaires et d'évaluer la rentabilité selon le temps, les produits et les clients.

Les délais de livraison, de préparation et de transport servent à analyser l'efficacité des processus logistiques et à identifier les sources de retard. Enfin, le retard de livraison constitue un indicateur clé de la qualité de service et un support pertinent pour les analyses avancées, notamment la segmentation des clients par des techniques de Data Mining.

2 Identification des dimensions

Les dimensions constituent les axes d'analyse permettant d'explorer les faits de manière multidimensionnelle. Dans l'entrepôt de données comptoirDB, trois dimensions principales ont été retenues. Les dimensions principales sont :

— **Dimension Client (Dim Clients)** :permet d'analyser les ventes et les délais de livraison selon les caractéristiques des clients et leur localisation géographique.

— **Dimension Produit (Dim Produits))** :regroupe les informations relatives aux produits et aux catégories, facilitant l'analyse des performances commerciales par produit.

— **Dimension Temps (Dim Temps)))** :permet l'analyse temporelle des ventes et des délais de livraison selon le jour, le mois, le trimestre et l'année.

3 Schéma en étoile

Le modèle conceptuel retenu est un schéma en étoile (Star Schema), car il permet une représentation intuitive et performante des données analytiques. La table de faits centrale est reliée directement à chaque dimension.

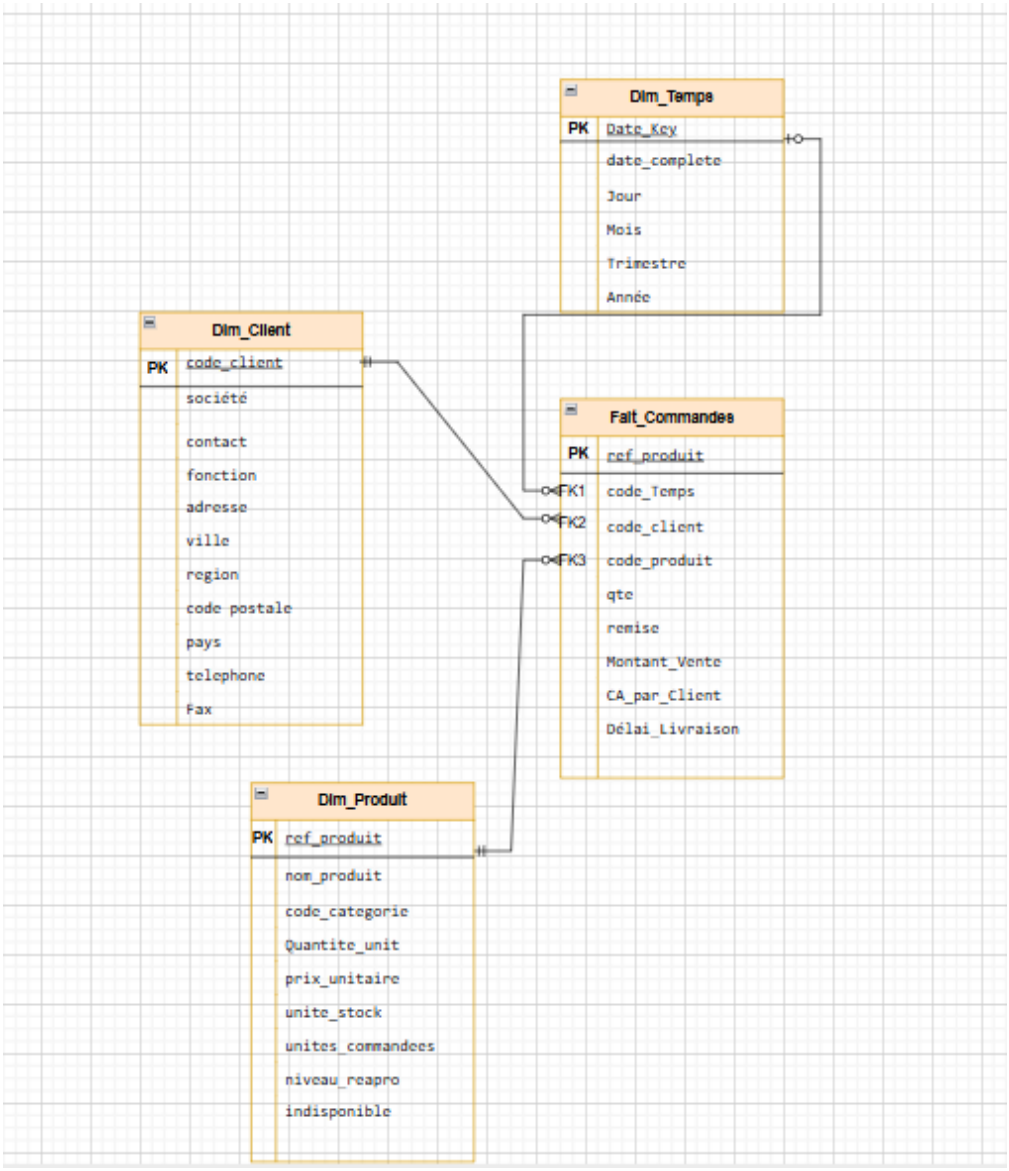


FIGURE 1 – Modèle en étoile de Gestion des Commandes et livraison

Ce modèle offre plusieurs avantages :

— Simplicité de navigation dans les données.

— Rapidité des requêtes multidimensionnelles (OLAP).

— Extensibilité en cas d'évolution du système.

4 Définition des métadonnées

Table de faits :

Attribut	Description	Type
Date_Key	Clé étrangère	Integer
Code_Client	Clé étrangère	Varchar
Ref_Produit	Clé étranère	Varchar
Prix_Unitaire	Mesure	Float
Quantite	Mesure	Integer
Remise	Mesure	Float
Montant_Vente	Mesure	Float
Montant_Net	Mesure	Float
Délai_Preparation	Mesure	Integer
Delai_Transport	Mesure	Integer
Delai_Livraison	Mesure	Integer
Retard_Livraison	Mesure	boolean

FIGURE 2 – table de faits Gestion des Commandes et livraison

Dimensions :

Dim Temps

Attribut	Description	Type
Date_Key	Clé primaire	Integer
Date_Complète	Date Commande complète	Date
Jour	Extraction du jour	Integer
Mois	Extraction du mois	Integer
Trimestre	Trimestre 3 mois	Integer
Année	Extraction	Integer

FIGURE 3 – dim Temps

Dim Client

Attribut	Description	Type
Code_Client	Clé primaire	Varchar
Societe	Niom de l'entreprise cliente	Varchar
Contact	Nom de la personne	Varchar
Fonction	Fonction ou poste	Varchar
Adresse	Adresse complète du client	Varchar
Ville	Ville du client	Varchar
Region	Region du Client	Varchar
Code_Postale	Code postal du client	Varchar
Pays	Pays du client	Varchar
Telephone	Numéro de téléphone du client	Varchar
Fax	Numéro de fax du client	Varchar

FIGURE 4 – dim Client

Dim produit

Attribut	Description	Type
Ref_Produit	Clé primaire	Varchar
Nom_Produit	Niom de produit	Varchar
Code_Categorie	Nom de la categorie	Varchar
Nom_Categorie	nom de la categorie	Varchar
Quantite_Unite	Quantité	Float
Prix_Unitaire	Prix Unitaire	Float
Unite_Stock	quantité stocké	Float
Unite_Commandee	quantité commandé	Float
Niveau_Reapro	Seuil min d'unité commandé	Int
Indisponible	le produit si indisponible ou non	Boolean

FIGURE 5 – dim produit

Conclusion

La modélisation multidimensionnelle présentée dans ce chapitre constitue le socle fondamental du système décisionnel proposé. Grâce à une structuration claire autour d'un schéma en étoile, les données de gestion des déchets peuvent désormais être explorées selon des axes multiples et répondre à des besoins analytiques variés. La prochaine étape consistera à alimenter cet entrepôt via un processus ETL robuste et cohérent.

Intégration des Données (Processus E

Introduction

Dans ce chapitre, nous détaillons la mise en œuvre du processus ETL (Extraction, Transformation, Chargement) pour alimenter l'entrepôt de données destiné à la gestion des ventes et livraison. Cette étape constitue un maillon essentiel entre les données brutes et le modèle décisionnel.

5 Présentation globale du processus ETL

Le processus ETL se compose de trois étapes :

1. **Extraction :** récupération des données à partir de fichier CSV.
2. **Transformation :** nettoyage, formatage et enrichissement des données.
3. **Chargement :** insertion dans l'entrepôt de données.

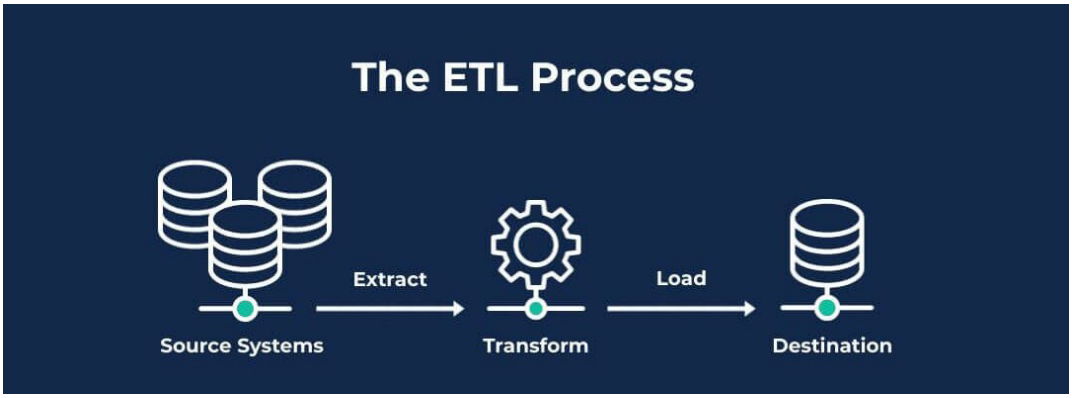


FIGURE 6 – Vue globale du processus ETL

6 Technologies utilisées

— Talend Open Studio for Data Integration : un outil d'intégration de données qui facilite la création de flux ETL (Extraction, Transformation, Chargement) en offrant une interface intuitive basée sur le glisser-déposer. Talend permet de connecter facilement différentes sources de données, de transformer les données selon les besoins et de les charger vers des destinations variées comme des bases de données.



FIGURE 7 – Talend Open Studio

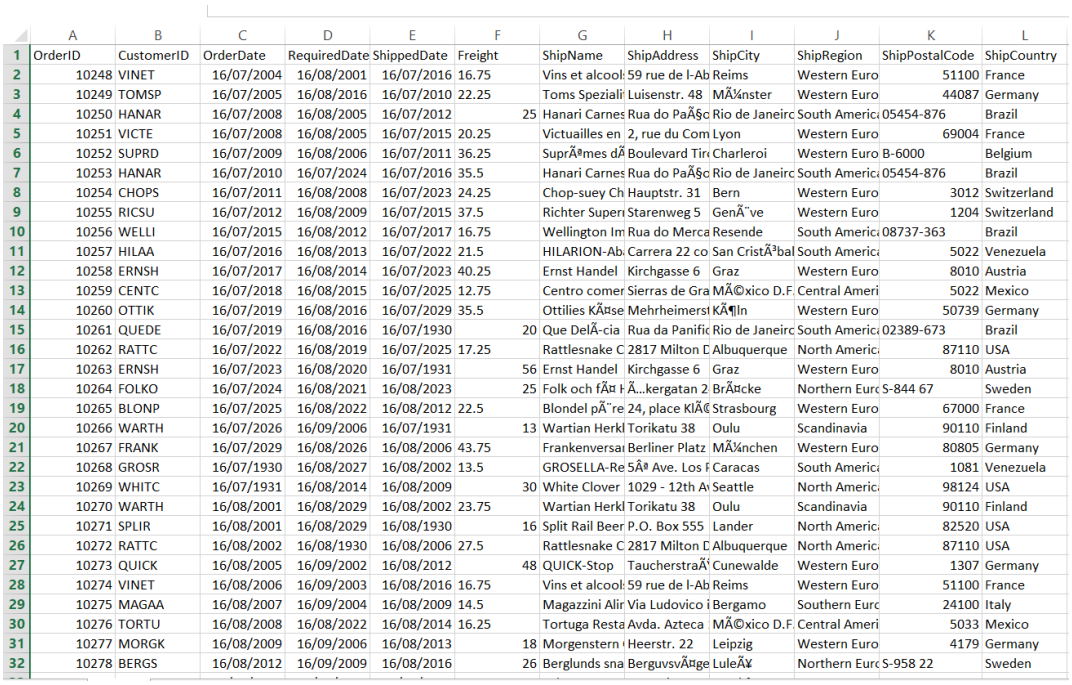
— Microsoft SQL SERVER SQL Server sert de source et/ou de destination pour stocker les données avant et après les traitements ETL. Avec Talend, il reçoit les données extraites, nettoyées et transformées pour les centraliser de façon fiable. Il permet ensuite d'interroger, analyser et alimenter l'entrepôt ou les rapports décisionnels.



Figure 8 – SQL Server

7 Présentation des données sources

Les données de départ sont stockées dans des fichiers CSV comportant plusieurs colonnes, notamment : fichier CSV Commandes contient : OderId,CustomerId,OrderDate,shipName,ShipCity,ShipRegion,ShipPostalCode



	A	B	C	D	E	F	G	H	I	J	K	L
1	OrderID	CustomerID	OrderDate	RequiredDate	ShippedDate	Freight	ShipName	ShipAddress	ShipCity	ShipRegion	ShipPostalCode	ShipCountry
2	10248	VINET	16/07/2004	16/08/2001	16/07/2016	16.75	Vins et alcool	59 rue de l-Ab	Reims	Western Euro	51100	France
3	10249	TOMSP	16/07/2005	16/08/2016	16/07/2010	22.25	Toms Speziali	Luisenstr. 48	MÃ¼nster	Western Euro	44087	Germany
4	10250	HANAR	16/07/2008	16/08/2005	16/07/2012	25	Hanari Carnes	Rua do PaÃ§o	Rio de Janeirc	South Americ	05454-876	Brazil
5	10251	VICTE	16/07/2008	16/08/2005	16/07/2015	20.25	Victuailles en	2, rue du Com	Lyon	Western Euro	69004	France
6	10252	SUPRD	16/07/2009	16/08/2006	16/07/2011	36.25	SuprÃªmes dÃ	Boulevard Tir	Charleroi	Western Euro	B-6000	Belgium
7	10253	HANAR	16/07/2010	16/07/2024	16/07/2016	35.5	Hanari Carnes	Rua do PaÃ§o	Rio de Janeirc	South Americ	05454-876	Brazil
8	10254	CHOPS	16/07/2011	16/08/2008	16/07/2023	24.25	Chop-suey Ch	Hauptstr. 31	Bern	Western Euro	3012	Switzerland
9	10255	RICSU	16/07/2012	16/08/2009	16/07/2015	37.5	Richter Super	Starenweg 5	GenÃ¨ve	Western Euro	1204	Switzerland
10	10256	WELLI	16/07/2015	16/08/2012	16/07/2017	16.75	Wellington Im	Rua do Merca	Resende	South Americ	08737-363	Brazil
11	10257	HILAA	16/07/2016	16/08/2013	16/07/2022	21.5	HILARION-Ab	Carrera 22 co	San CristÃ³bal	South Americ	5022	Venezuela
12	10258	ERNSH	16/07/2017	16/08/2014	16/07/2023	40.25	Ernst Handel	Kirchgasse 6	Graz	Western Euro	8010	Austria
13	10259	CENTC	16/07/2018	16/08/2015	16/07/2025	12.75	Centro comer	Sierras de Gra	MÃ©xico D.F.	Central Ameri	5022	Mexico
14	10260	OTTIK	16/07/2019	16/08/2016	16/07/2029	35.5	Ottilies KÃ¤se	Mehrheimerst	KÃ¶ln	Western Euro	50739	Germany
15	10261	QUEDE	16/07/2019	16/08/2016	16/07/1930	20	Que DelÃ-cia	Rua da Panific	Rio de Janeirc	South Americ	02389-673	Brazil
16	10262	RATTC	16/07/2022	16/08/2019	16/07/2025	17.25	Rattlesnake C	2817 Milton D	Albuquerque	North Americ	87110	USA
17	10263	ERNSH	16/07/2023	16/08/2020	16/07/1931	56	Ernst Handel	Kirchgasse 6	Graz	Western Euro	8010	Austria
18	10264	FOLKO	16/07/2024	16/08/2021	16/08/2023	25	Folk och fÃ¤ H	Ã…kergatan 2	BrÃ¤cke	Northern Euro	S-844 67	Sweden
19	10265	BLONP	16/07/2025	16/08/2022	16/08/2012	22.5	Blondel pÃ¨re	24, place KlÃ(	Strasbourg	Western Euro	67000	France
20	10266	WARTH	16/07/2026	16/09/2006	16/07/1931	13	Wartian Herkl	Torikatu 38	Oulu	Scandinavia	90110	Finland
21	10267	FRANK	16/07/2029	16/08/2026	16/08/2006	43.75	Frankenversa	Berliner Platz	MÃ¼nchen	Western Euro	80805	Germany
22	10268	GROSR	16/07/1930	16/08/2027	16/08/2002	13.5	GROSELLA-Re	5Âª Ave. Los P	Caracas	South Americ	1081	Venezuela
23	10269	WHITC	16/07/1931	16/08/2014	16/08/2009	30	White Clover	1029 - 12th Av	Seattle	North Americ	98124	USA
24	10270	WARTH	16/08/2001	16/08/2029	16/08/2002	23.75	Wartian Herkl	Torikatu 38	Oulu	Scandinavia	90110	Finland
25	10271	SPLIR	16/08/2001	16/08/2029	16/08/1930	16	Split Rail Beer	P.O. Box 555	Lander	North Americ	82520	USA
26	10272	RATTC	16/08/2002	16/08/1930	16/08/2006	27.5	Rattlesnake C	2817 Milton D	Albuquerque	North Americ	87110	USA
27	10273	QUICK	16/08/2005	16/09/2002	16/08/2012	48	QUICK-Stop	TaucherstraÃ	Cunewalde	Western Euro	1307	Germany
28	10274	VINET	16/08/2006	16/09/2003	16/08/2016	16.75	Vins et alcool	59 rue de l-Ab	Reims	Western Euro	51100	France
29	10275	MAGAA	16/08/2007	16/09/2004	16/08/2009	14.5	Magazzini Alir	Via Ludovico i	Bergamo	Southern Eurc	24100	Italy
30	10276	TORTU	16/08/2008	16/08/2022	16/08/2014	16.25	Tortuga Resta	Avda. Azteca	MÃ©xico D.F.	Central Ameri	5033	Mexico
31	10277	MORGK	16/08/2009	16/09/2006	16/08/2013	18	Morgenstern (	Heerstr. 22	Leipzig	Western Euro	4179	Germany
32	10278	BERGS	16/08/2012	16/09/2009	16/08/2016	26	Berglunds sna	BerguvsvÃ¤ge	LuleÃ¥	Northern Euro	S-958 22	Sweden

FIGURE 9 – fichier orders.csv

8 Préparation des données sources

L'objectif est d'extraire les données brutes du fichier CSV contenant les informations nécessaires à la construction du l'entrepôt de données. À l'aide de Talend, ce processus se déroule en trois étapes principales : l'extraction des données depuis le fichier source à l'aide d'un composant de lecture, la transformation pour nettoyer, formater et organiser les données en fonction des exigences du l'entrepôt de données, et enfin le chargement des données transformées dans la base de données cible.

Extraction des données source

cette étape consiste à lire les données brutes depuis le fichier CSV (délimité). Pour cela, nous avons utilisé le composant tFileInputDelimited de Talend. • tFileInputDelimited : est un composant disponible dans les métadonnées, permet de lire des fichiers délimités (comme les CSV). Il extrait les données ligne par ligne en spécifiant des paramètres tels que le chemin du fichier, le séparateur et l'encodage, les rendant prêtes pour les transformations.

Processus détaillé

1. Nous débutons par la création d'un nouveau Job(jCommandes) :

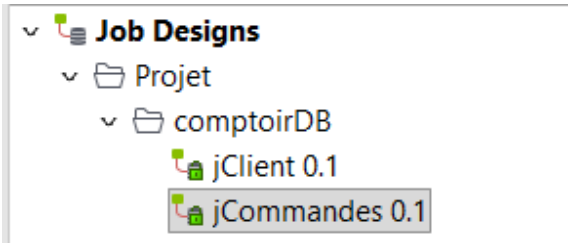


FIGURE 10 – job JCommandes créé avec succès

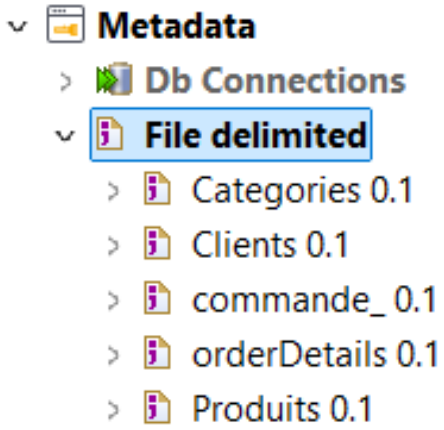


FIGURE 11 – fichier délimité créé avec succés.

2. On glisse le composant tFileInputDelimited sur le Job et le-relier au composant tLogRow afin d'afficher les données extraites du fichier CSV dans la console pour une vérification visuelle.

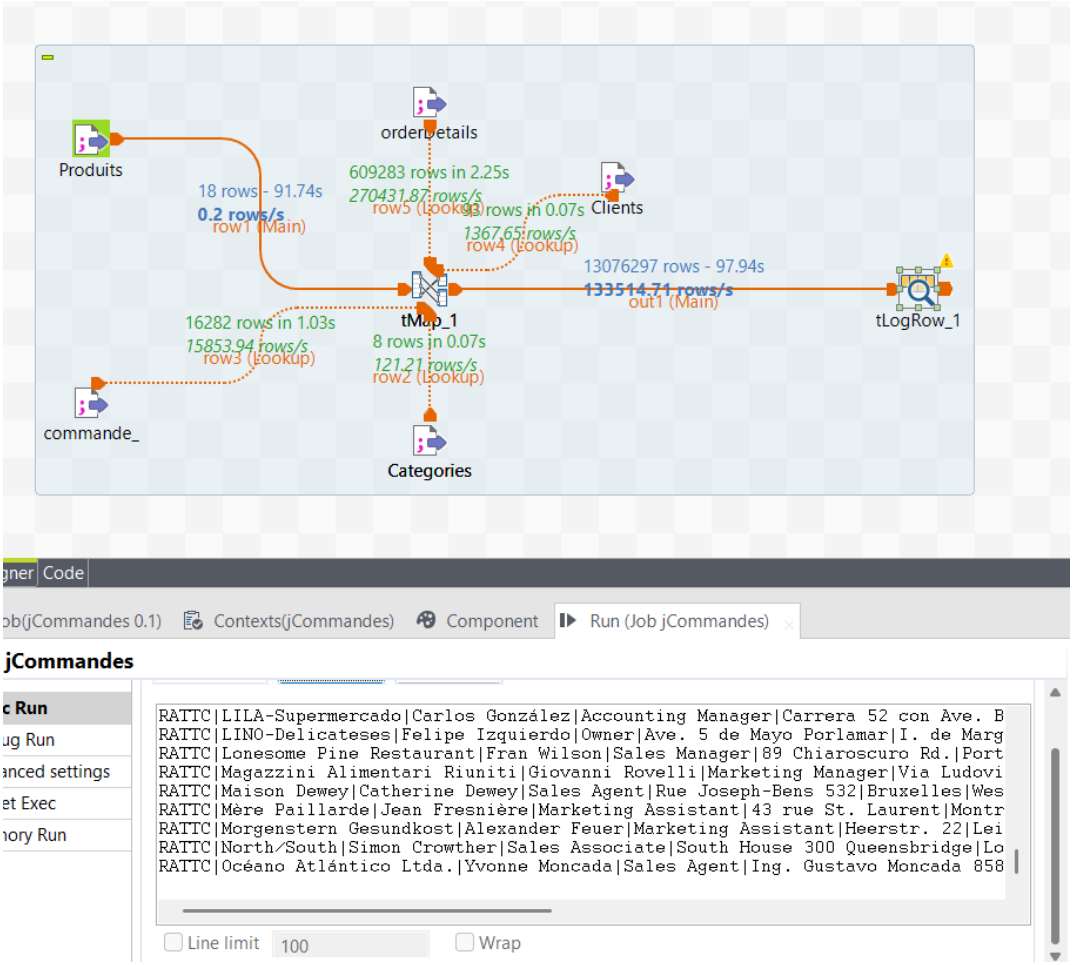


FIGURE 12 – Visualisation des données extraites dans la console.

8.1 Transformation des données

Lors de cette étape, le composant tMap est utilisé pour effectuer les transformations nécessaires. Il permet de réaliser des opérations de nettoyage, de filtrage, de mapping et d'enrichissement des données. Cette étape prépare les données afin de les rendre conformes au modèle multidimensionnel du l'entrepôt de données.

Processus détaillé

1. Glisser le composant tmap et le relier avec tFileInputDelimited :

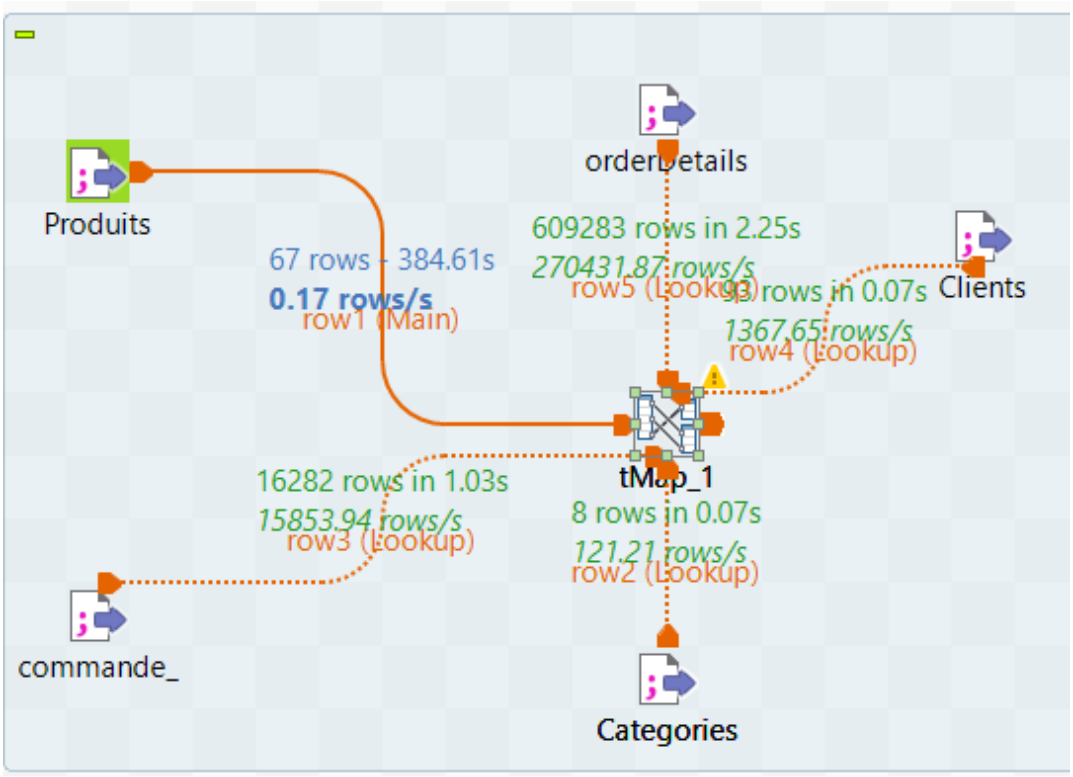


FIGURE 13 – Composant TMap connecté avec succès.

2. Après avoir configuré le composant tMap, nous créons plusieurs sorties distinctes correspondant au tables de base de données comptoir (base intermédiaire)

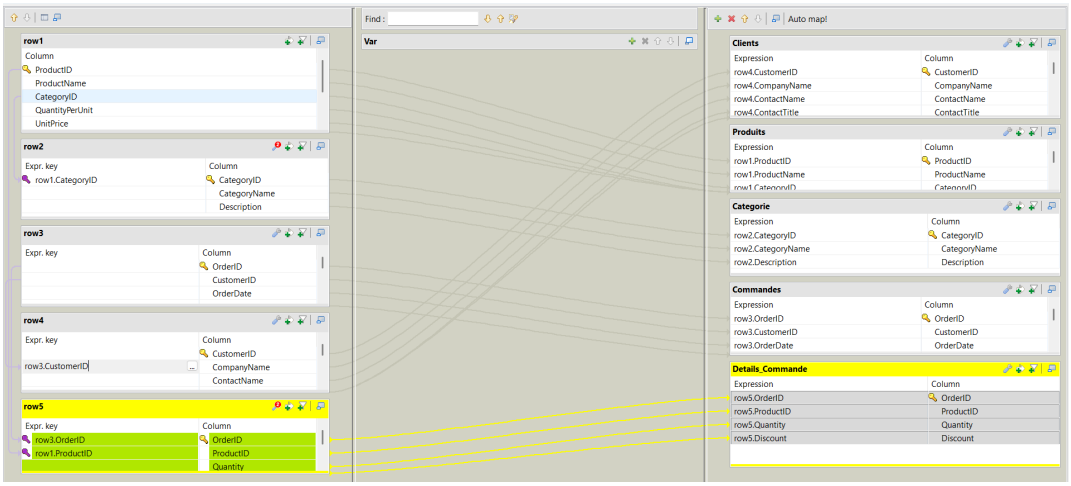


FIGURE 14 – Configurations tmap.

Chargement dans la base de données intermédiair

Afin d'assurer la cohérence des formats et des types de données avant le chargement, nous avons créé une base de données intermédiaire nommée "ComptoirDB". Cette étape facilite la gestion et la validation des données transformées en les organisant dans des tables de dimensions (temps, zone géographique, type de déchets, méthode de traitement, trajet.), préparant ainsi efficacement leur intégration dans le Data Warehouse.

Processus détaillé

1. Créer la base de données intermédiaire nommée "ComptoirDB" via l'interface de Microsoft SQL Server.
2. Dans Talend, nous créons une nouvelle connexion à la base de données intermédiaire en précisant la version de SQL Server, l'identifiant utilisateur, le port, le serveur (localhost) ainsi que le nom de la base de données "ComptoirDB" précédemment créée.

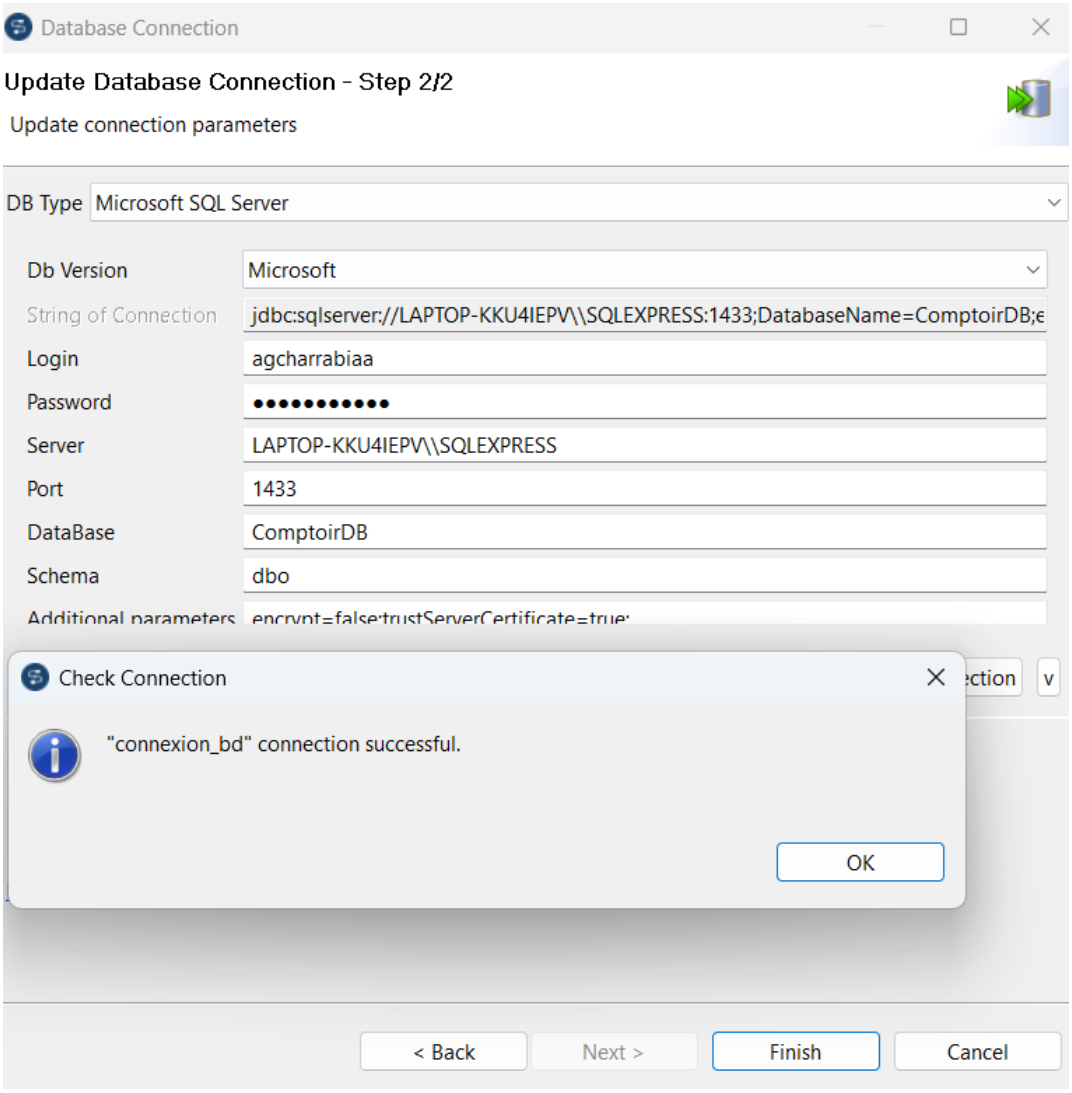


FIGURE 15 – Connexion au bd ComptoirDB.

3. Ajouter les composant tDBOutput dans Talend, qui permet d'écrire les données transformées directement dans les tables de la base de données intermédiaire. Chaque composant tDBOutput est ensuite relié au composant tMap afin d'assurer que les données transformées et mappées soient insérées dans les tables correspondantes.

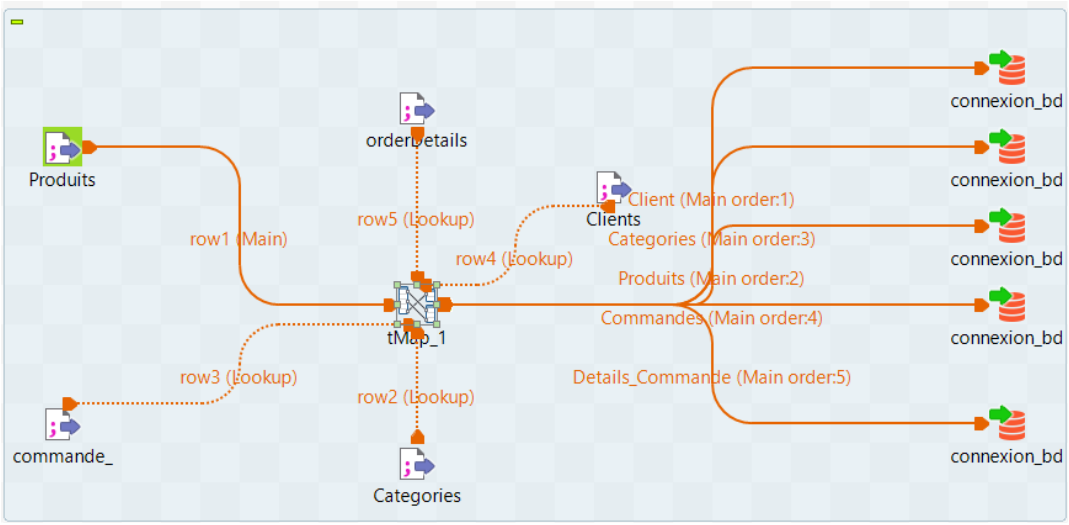


FIGURE 16 – Connexion des composants tDBOutput avec tMap.

4. Pour chaque composant tDBOutput, on associe le nom de la table correspondante et on effectue les configurations nécessaires afin de garantir la création correcte des tables dans la base de données.

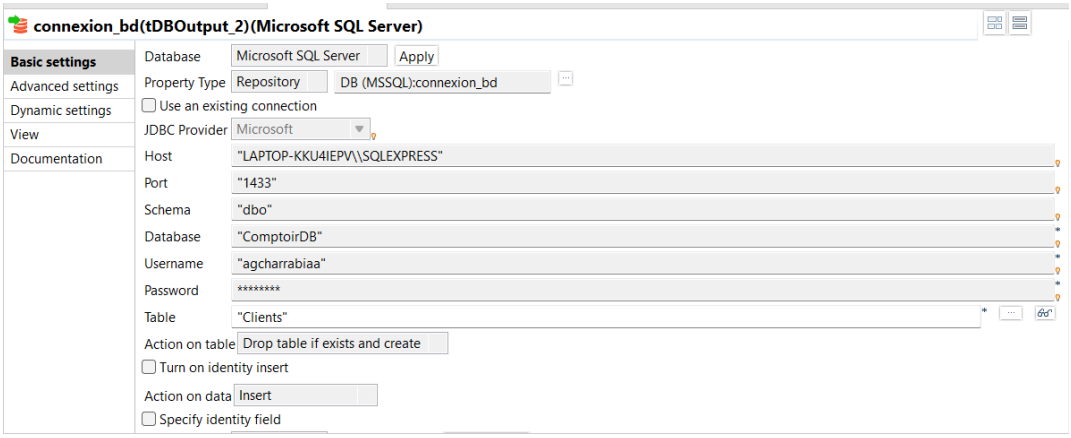


FIGURE 17 – Configuration des tDBOutput pour la création des tables.

5. On exécute le job intitulé "jCommandes" pour valider le chargement des données dans les tables de la base de données intermédiaire.

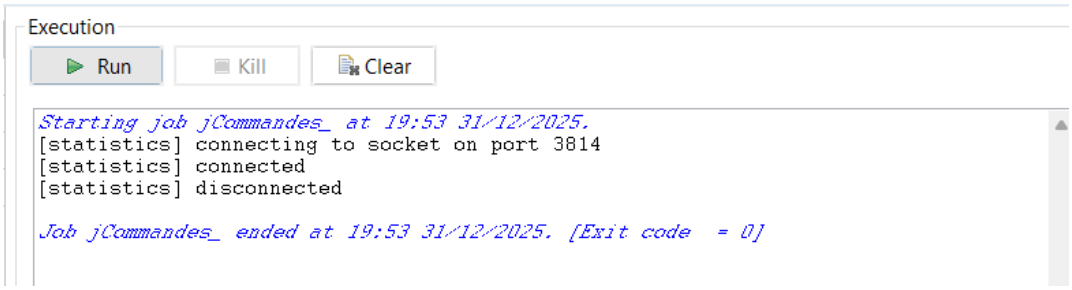


FIGURE 18 – Execution de job avec succés..

6. On vérifier le chargement des tables dans la base de données intermédiaire "ComptoirDB".

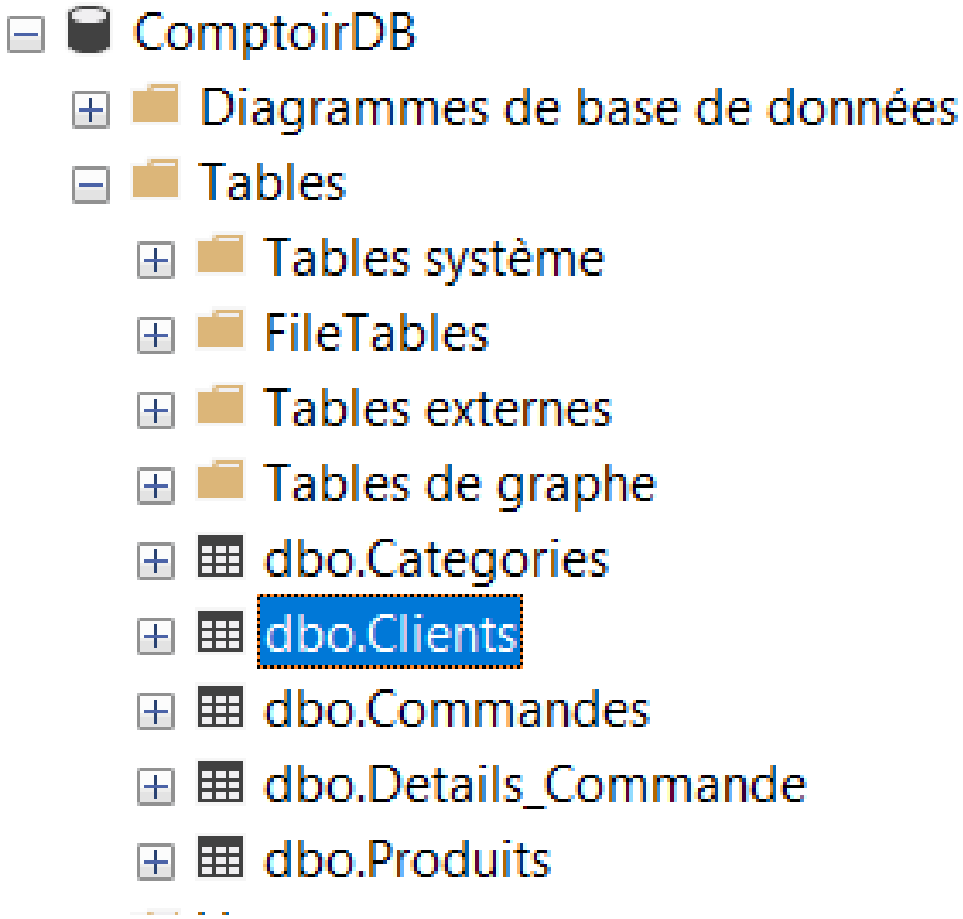


FIGURE 19 – Chargement des tables dans la base de données.

Extraction des données depuis la base intermédiaire

Afin de construire l'entrepôt de données final, les données ont été extraites depuis la base intermédiaire et enregistrées dans une nouvelle base de données nommée "ComptoirDWH". Chaque table extraite correspond à une dimension spécifique, créée à l'aide de Talend, pour être intégrée dans le modèle multidimensionnel.

Processus détaillé

Le schéma de la base de données "ComptoirDB" est importé dans Talend pour permettre une utilisation efficace des données lors des opérations de transformation et de chargement. Récupération du schéma :

1. Récupération du schéma :

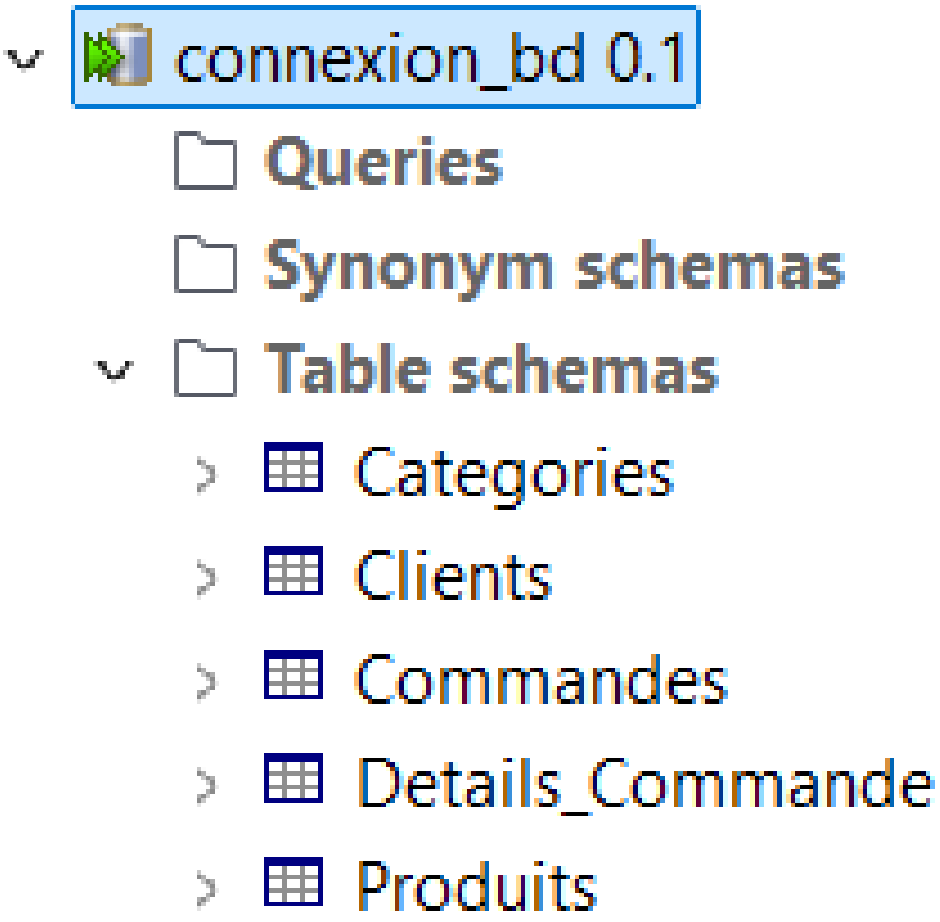


FIGURE 20 – récupération de schéma.

2. Création des jobes pour les dimensions Client et Produit :



FIGURE 21 – création dim$_{C}lient$

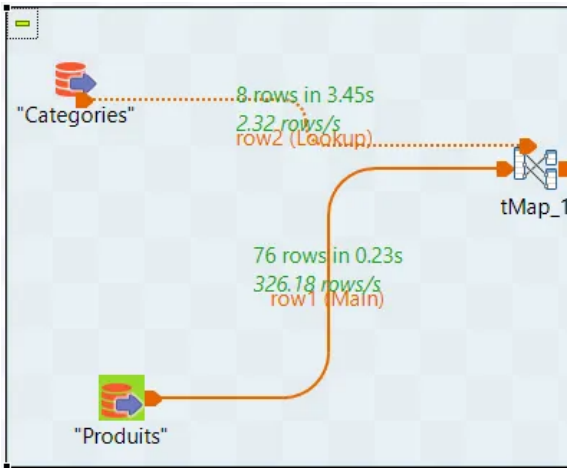


FIGURE 22 – création dim$_{P}roduit$.

3. Le composant tMap a servi à associer les colonnes des tables sources issues de la base intermédiaire aux tables correspondantes du l'entrepôt de données.

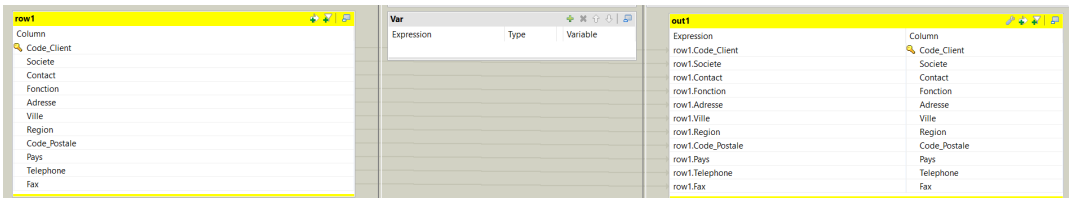


FIGURE 23 – mappage dim client

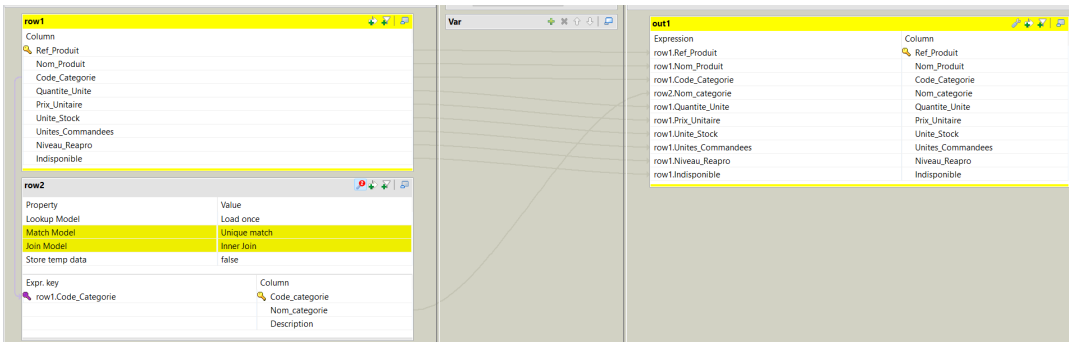


FIGURE 24 – mappage dim produit

8.2 Construction de dimension du temps

1. Récupérer la date de début (MIN orderDate) :

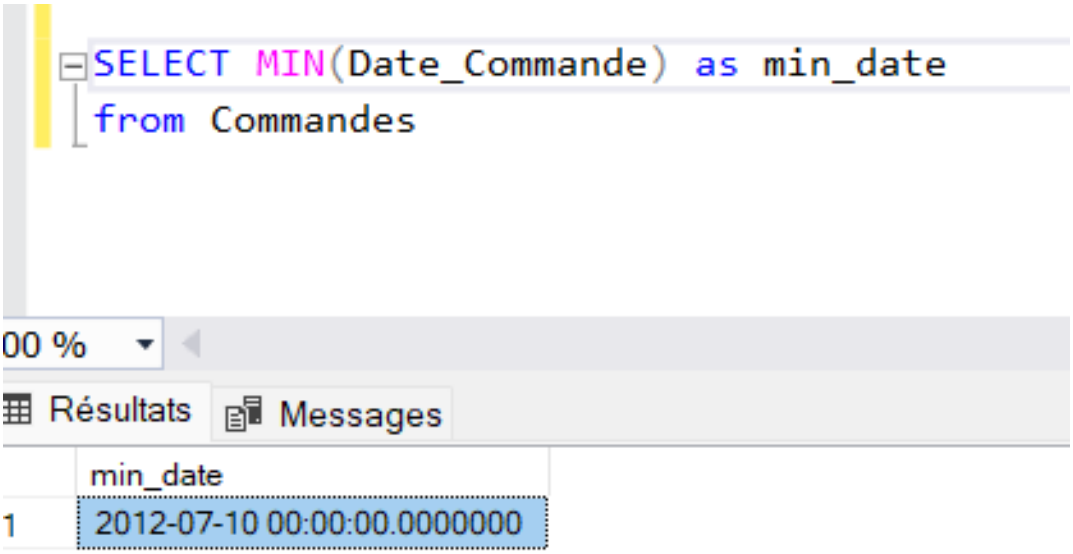


FIGURE 25 – mappage dim produit

2. Générer les dates Apartir de dateDebut :

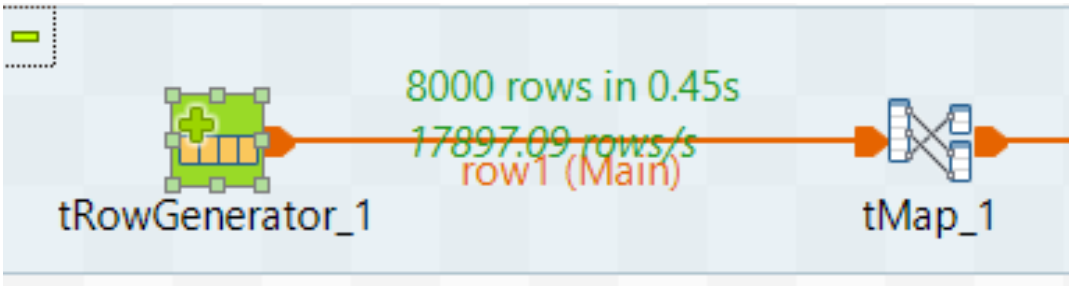


FIGURE 26 – générer des dates

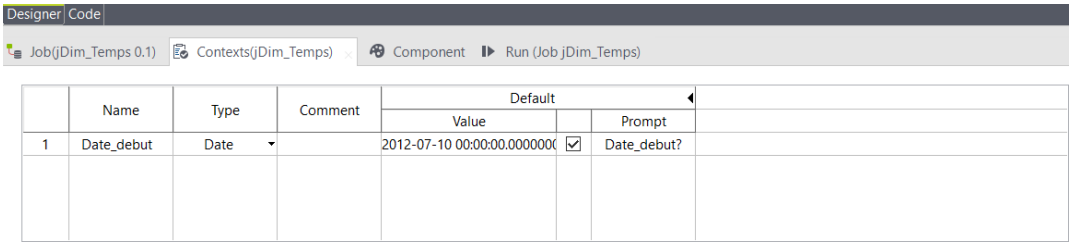


FIGURE 27 – création du variable contexte

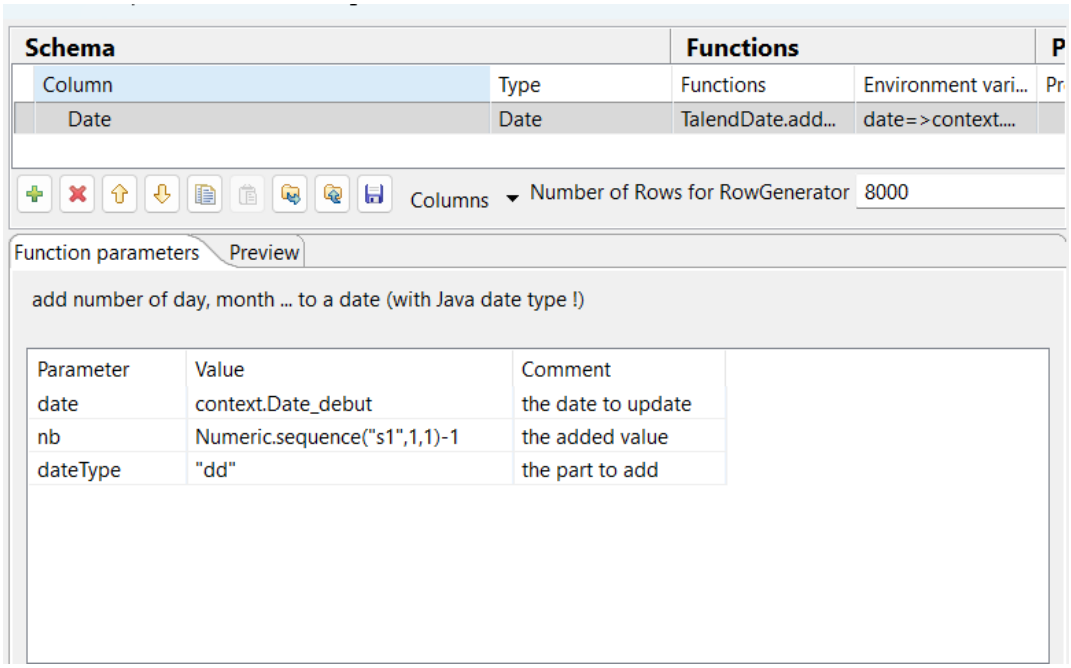


FIGURE 28 – générer des dates

3. Enrichir les attributs de la dimension temps :

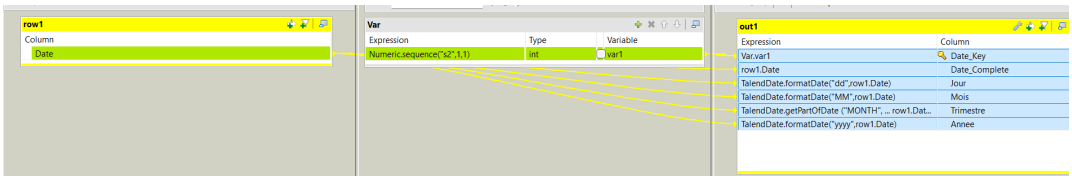


FIGURE 29 – mappage dim Temps

nous avons séparé les éléments d'une date complète issue de la base de données initiale en trois composantes distinctes : le jour, le mois et l'année. Cette opération, réalisée à l'aide de la fonction TalendDate.formatDate, permet de structurer les données temporelles pour une meilleure exploitation dans les analyses et facilite leur intégration dans la dimension Date d'un modèle multidimensionnel. Par exemple, une date comme "15/08/2023" a été décomposée en jour = 15, mois = 08, et année = 2023.

8.3 Chargement dans l'entrepôt de données

Les dimensions ont été structurées et chargées dans la base "ComptoirDWH" sous forme de tables individuelles. Chaque table contient les attributs requis pour construire les relations et permettre des analyses approfondies.

8.3.1 Processus détaillé :

1. Créer nouvelle base de données nommée "ComptoirDWH" via l'interface Microsoft SQL Server.

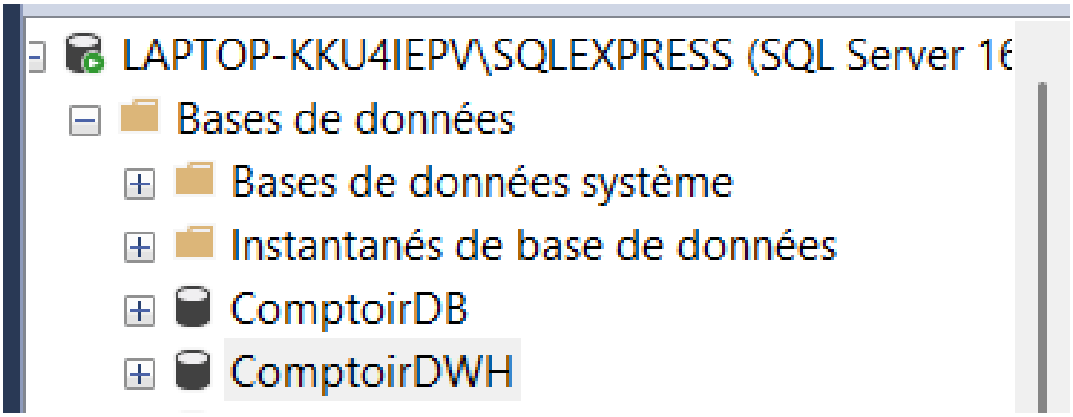


FIGURE 30 – Base de données ComptoirDWH

2. On crée une nouvelle connexion à la base de données en précisant la version de MySQL, l'identifiant utilisateur, le port, le serveur (localhost) ainsi que le nom de la base de données "datawarehouse" précédemment créée.

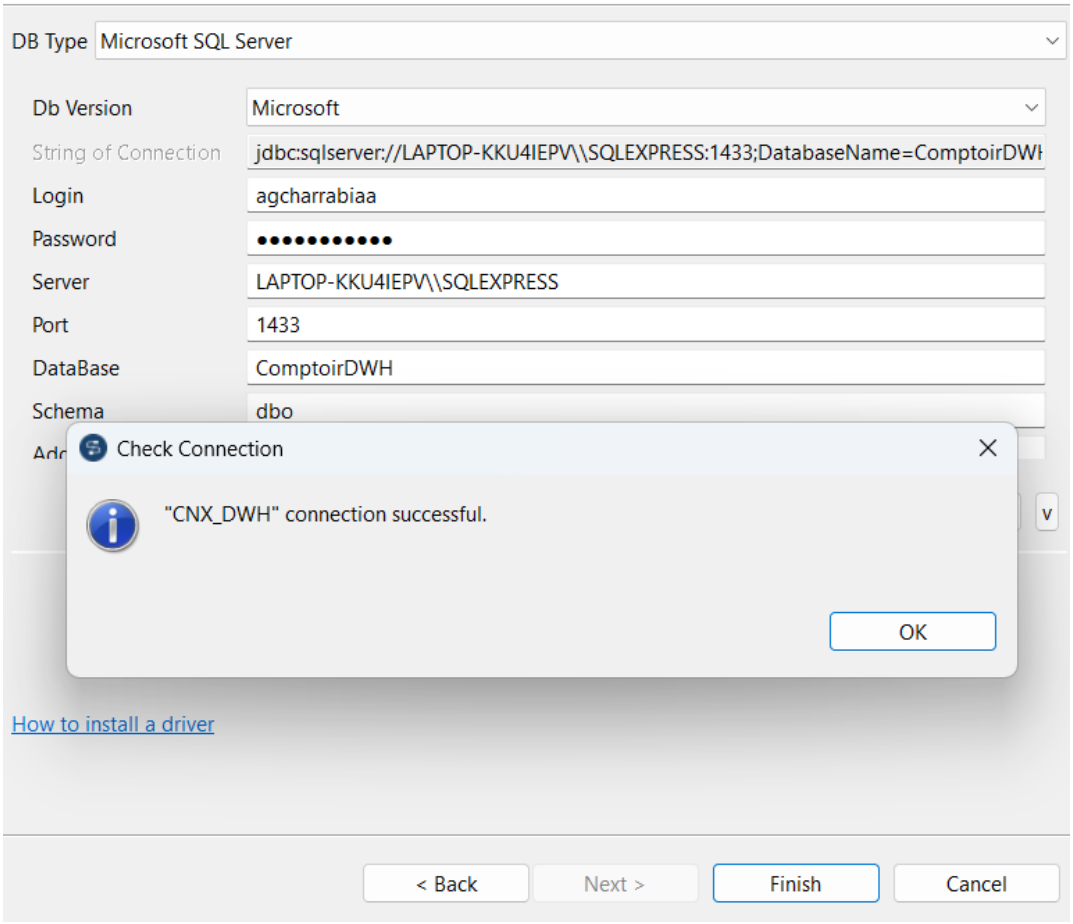


FIGURE 31 – connexion au Base de données ComptoirDWH

3. On Ajoute les composants tDBOutput de la base de données ComptoirDWH dans talend :

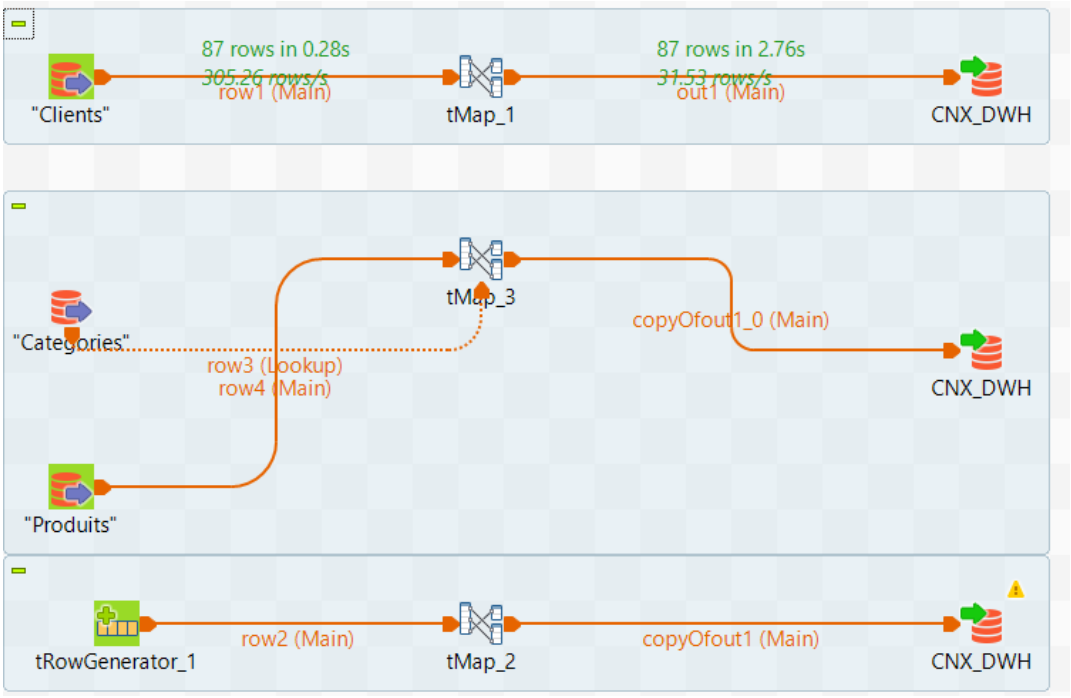


FIGURE 32 – Connexion de composant tDBOutput avec le tMap.

4. Pour chaque composant tDBOutput, on associe le nom de la table correspondante et on effectue les configurations nécessaires afin de garantir la création correcte des tables dans l'entrepôt de données.

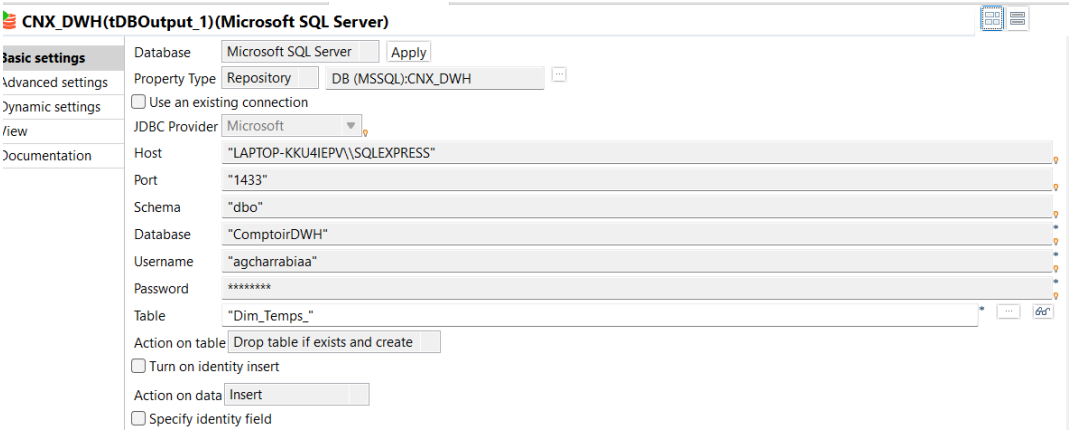


FIGURE 33 – Configuration de tDBOutput pour la création de table de faits.

5. On execute chaque job pour valider le chargement des données dans les tables de l'entrepôt de données.

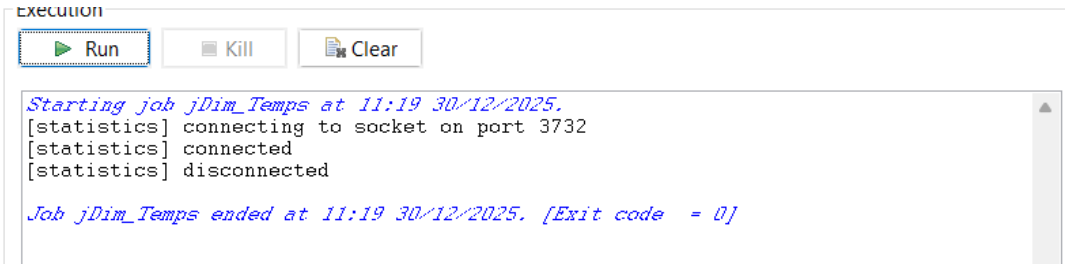


FIGURE 34 – Exécution de job avec succés..

6. On vérifier le chargement des tables dans l'entrepôt de données .

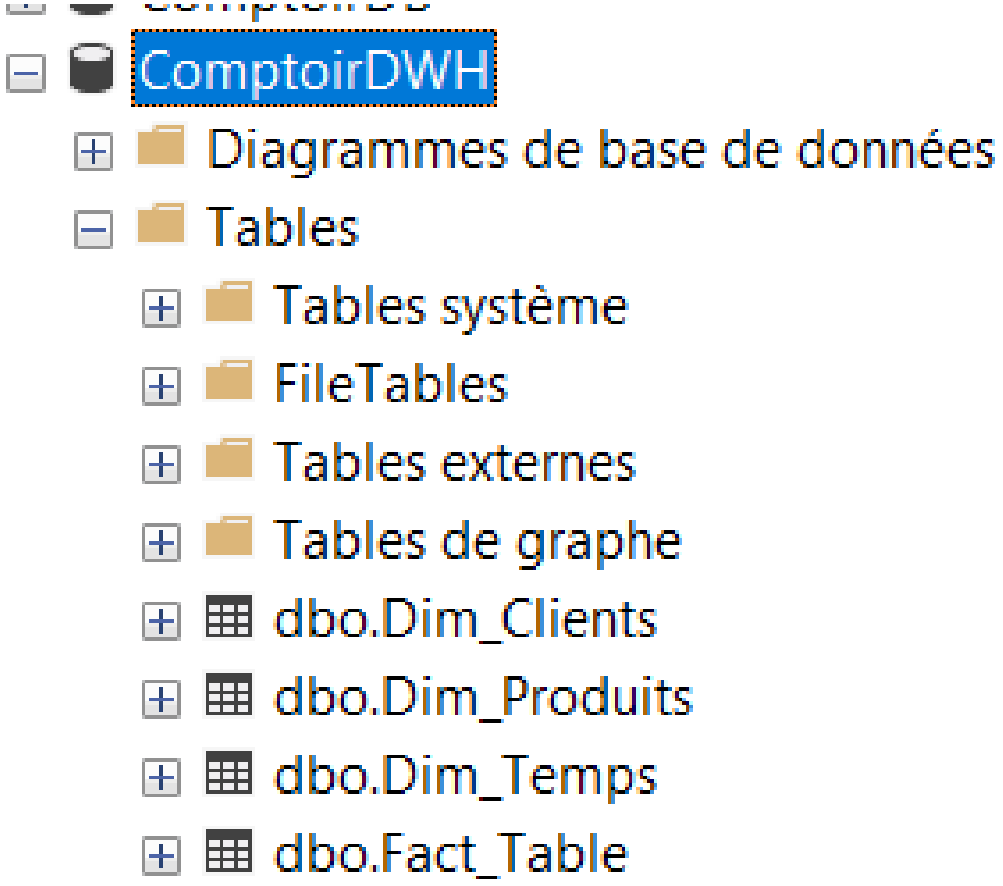


FIGURE 35 – Chargement des tables avec succès

Construction de la table de faits

Après le chargement des dimensions dans l'entrepôt de données (data warehouse), il reste à construire la table de faits nommée "Fact Table". Cette table relie les clés étrangères des différentes tables de dimensions et intègre les mesures nécessaires, calculées et extraites à partir de fichier source CSV. Elle joue un rôle central dans l'analyse en consolidant les informations essentielles pour le modèle multidimensionnel.

Étapes pour construction de la table de faits

Récupération des Données Nécessaires

Les clés primaires des dimensions sont extraites du DataWarehouse, et les données sources pour les mesures sont extraites à partir des fichiers d'origine.

Processus détaillé

1. On crée un nouveau job "jtable fait".

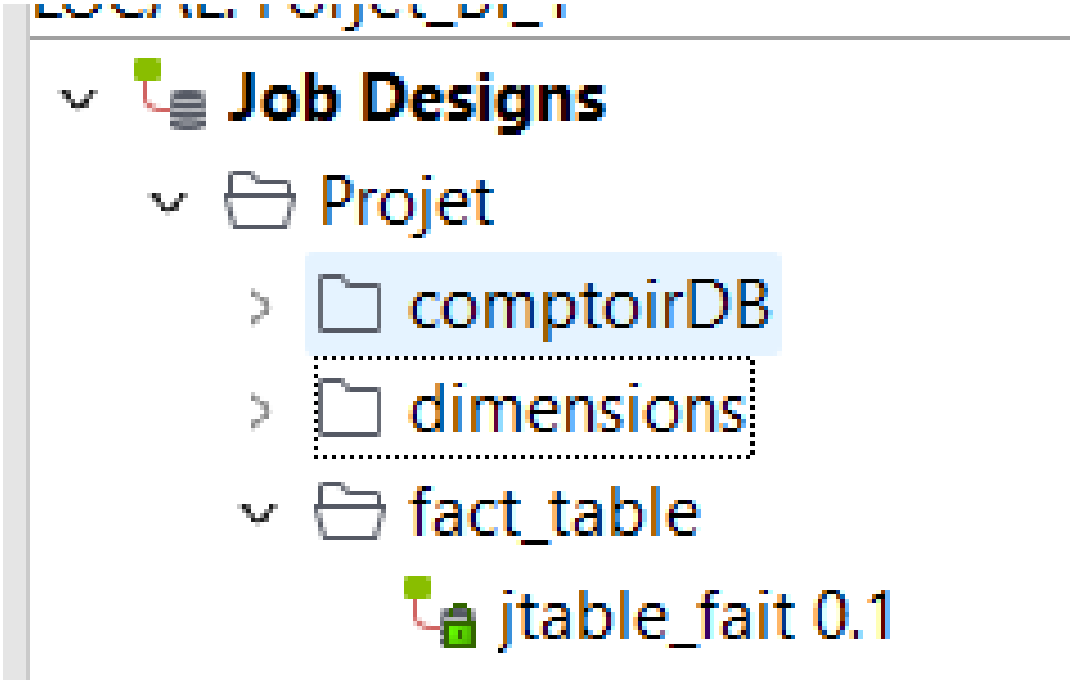


FIGURE 36 – creation du job jtable fait

2. Le schéma de entrepôt de données est importé dans Talend pour permettre une utilisation efficace des données lors des opérations de transformation et de chargement du table de faits.

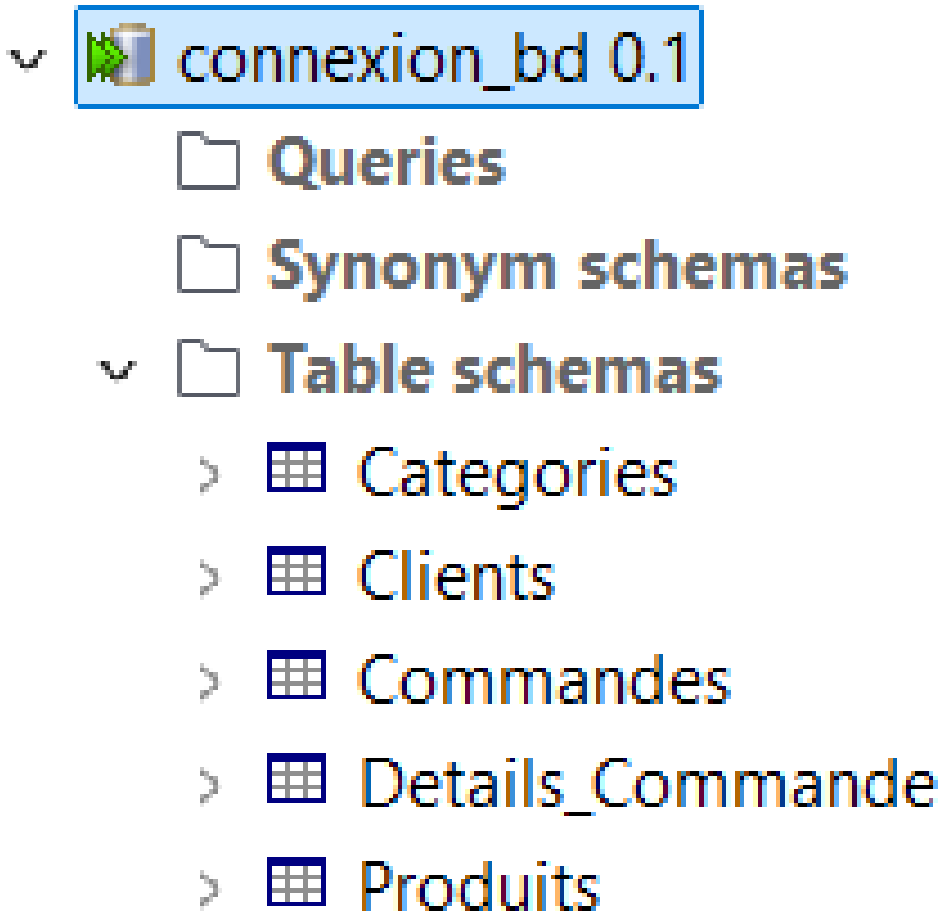


FIGURE 37 – Récupération du shèma

3. On ajoute les composants tDBInput (SQL Server) pour chaque table représentant une dimension du ComptoirDWH et les tables Commandes,Details Commande dans la base de donnée intermidiaire ComptoirDB, en les configurant à partir des schémas récupérés.Glissez ensuite ces composants dans l'espace de travail de notre job dans Talend.

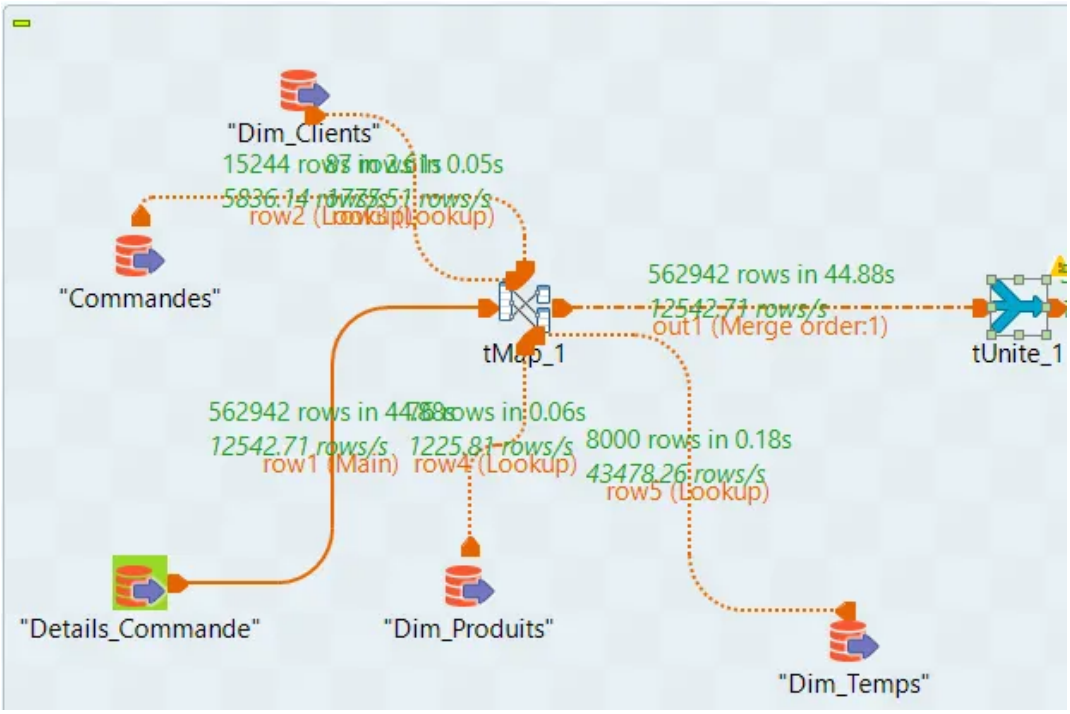


FIGURE 38 – Intégration des composants dans job

8.3.2 Transformations et Configuration

Dans le composant tMap, les clés primaires des dimensions extraites des tables du Data Warehouse ont été mappées aux colonnes correspondantes du fichier source initial. Cette étape établit les relations logiques nécessaires entre les dimensions et les mesures, assurant ainsi une structure cohérente pour la table de faits.

8.3.3 Processus détaillé

1. Dans le tMap, les liens violets représentent les clés étrangères qui connectent les colonnes des dimensions à la table de faits.

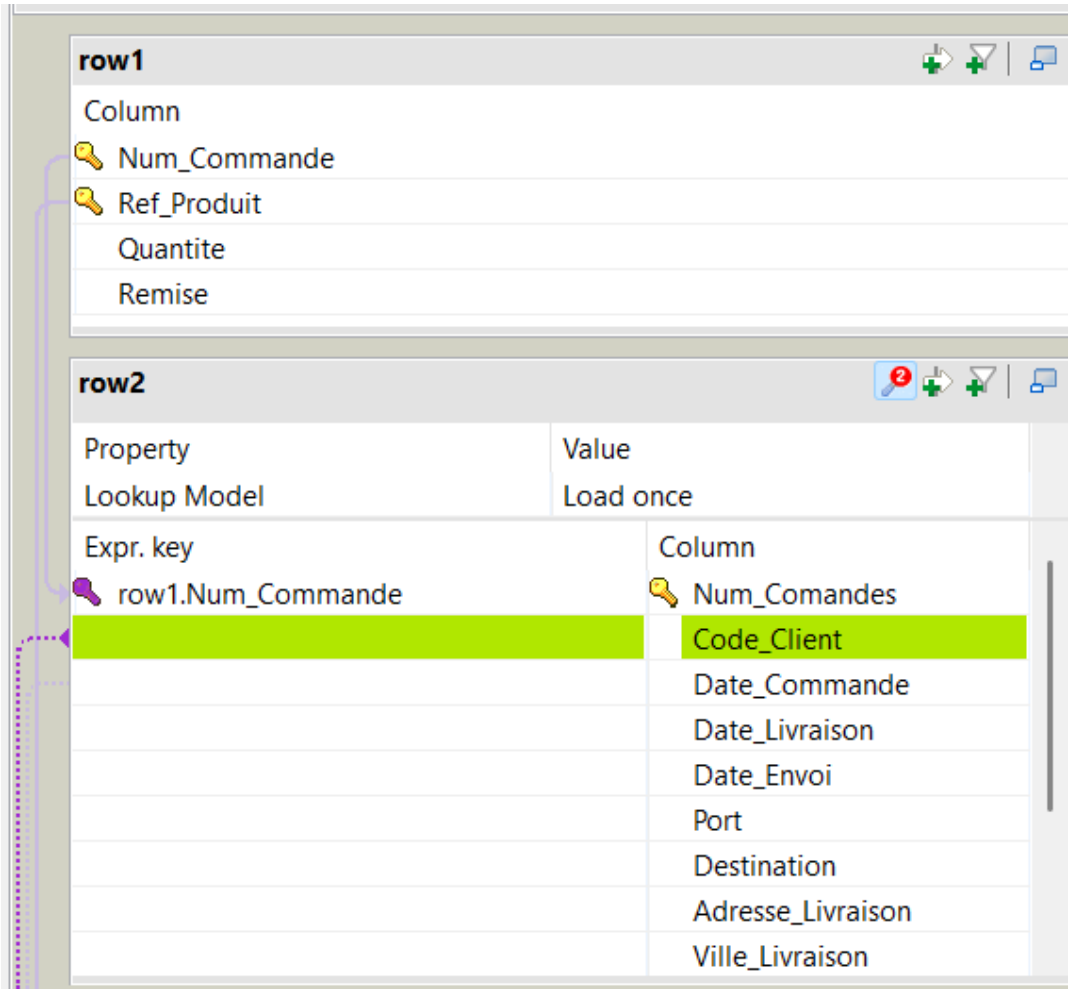


FIGURE 39 – Génération des clés étrangères.

2. Pour les mesures telles que le montant vente, le délai de livraison, nous les calculons à partir du mappage des colonnes nécessaires en lien avec les tables dedimensions.

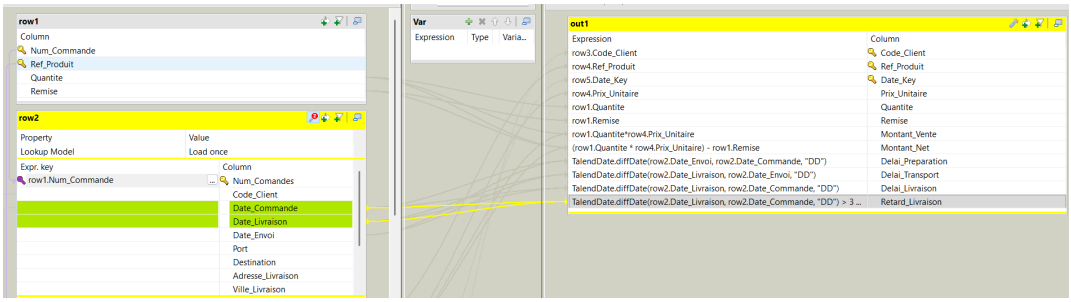


FIGURE 40 – Mappage des clés et les mesures

Chargement dans l'entrepôt de données

Après avoir généré les clés étrangères et calculé les mesures nécessaires, la table de faits est désormais prête à être chargée dans l'entrepôt de données. Ce processus assure l'intégration complète des dimensions

et des mesures dans le modèle multidimensionnel.

Processus détaillé

1. On Ajoute le composant tDBOutput de la base de données ComptoirDWH et le relier avec le composant tmap :

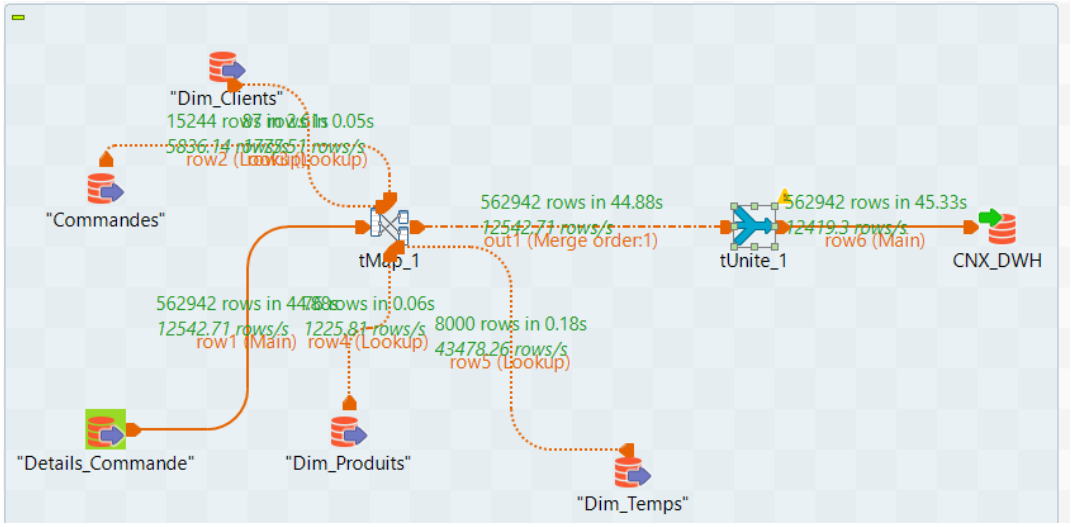


FIGURE 41 – Mappage des clés et les mesures

2. Dans le composant tDBOutput, on associe le nom : “Fact Table” et on effectue les configurations nécessaires afin de garantir la création correcte de la table dans l’entrepot de données :

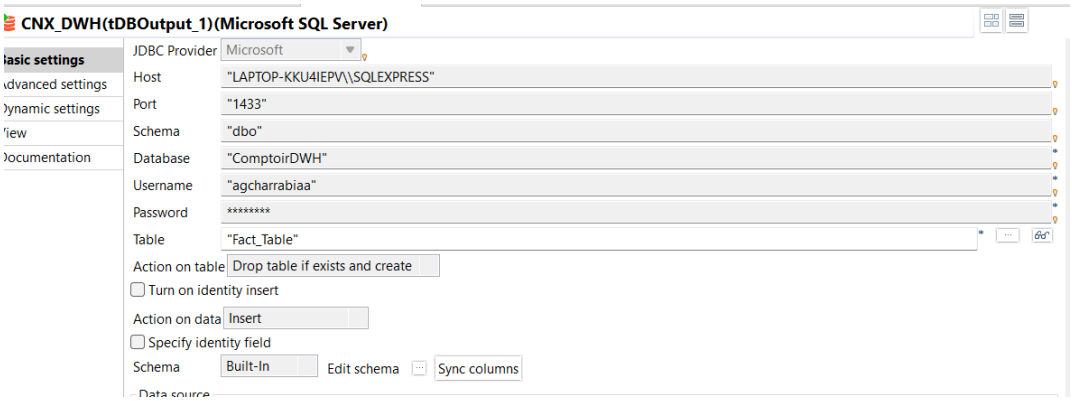


FIGURE 42 – Configuration de tDBOutput pour la création de table de faits.

3. On execute le job intitulé "Job table de fait " pour valider le chargement des données dans la table de l’entrepôt de données.

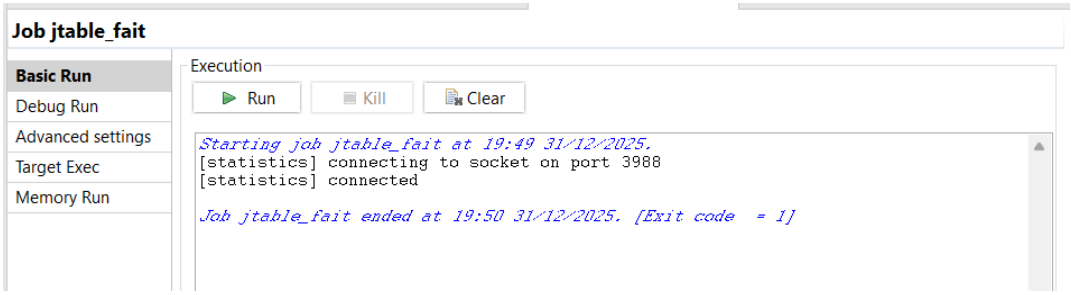


FIGURE 43 – Exécution de job avec succés.

4. On vérifier le chargement de la table de faits dans entrepôt de données.

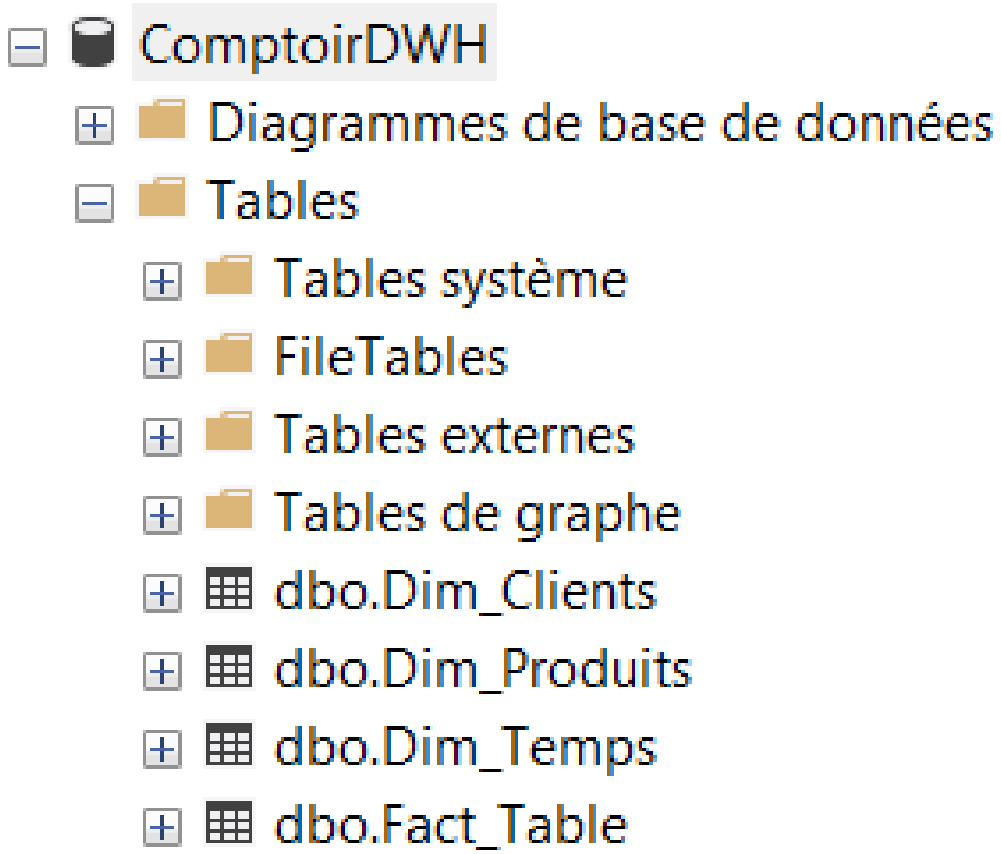


FIGURE 44 – Chargement de la table de fait dans l'entrepôt de données.

Conception du schéma conceptuel

Une fois la table de faits chargée dans l'entrepôt de données, nous pouvons concevoir le schéma conceptuel. Ce dernier représente les relations entre la table de faits et les différentes tables de dimensions, offrant ainsi une vue claire et structurée du modèle multidimensionnel.

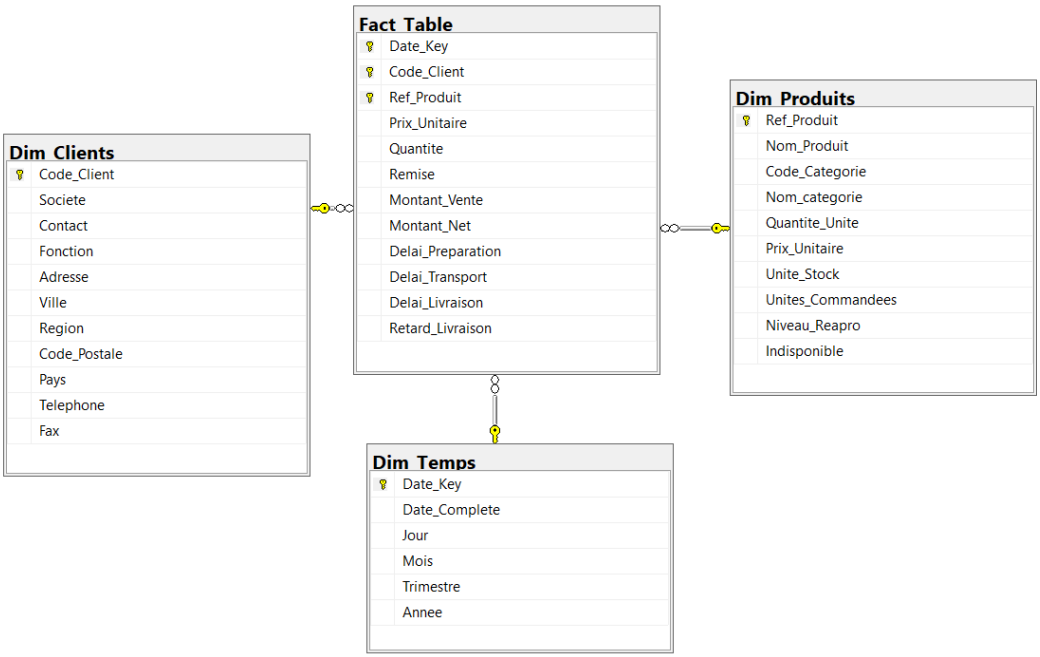


FIGURE 45 – Schèma Conceptuel.

Conclusion

Ce chapitre a exposé l'architecture et le déploiement du pipeline ETL avec Talend et MySQL. Cette étape prépare les données pour des analyses fiables, structurées et exploitables via des outils BI dans les prochains chapitres.

Conception et mise en œuvre du cub

Introduction

Après la création de la table de faits et des différentes dimensions dérivées de la base **ComptoirDB**, cette étape consiste à structurer ces données sous forme d'un cube OLAP afin de faciliter l'analyse décisionnelle. La table de faits regroupe les mesures essentielles liées aux ventes, tandis que les dimensions (clients, produits, employés, fournisseurs, temps, etc.) permettent d'analyser ces indicateurs selon plusieurs axes.

Cette organisation multidimensionnelle offre une vision claire et dynamique de l'activité commerciale. Elle permet le suivi des performances, la comparaison des périodes, l'analyse du comportement des clients ainsi que l'évaluation des produits et des régions, constituant ainsi une base solide pour l'aide à la décision.

9 Technologies utilisées

9.1 Visual Studio



FIGURE 46 – Environnement de développement Visual Studio

Visual Studio est utilisé comme environnement de développement intégré (IDE) pour la création du projet décisionnel. Il offre une interface graphique permettant de définir les sources de données, de concevoir la table de faits, les dimensions et de configurer le projet **Analysis Services**. Cet outil facilite le développement, la gestion et le déploiement du cube OLAP.

9.2 SQL Server Analysis Services (SSAS)

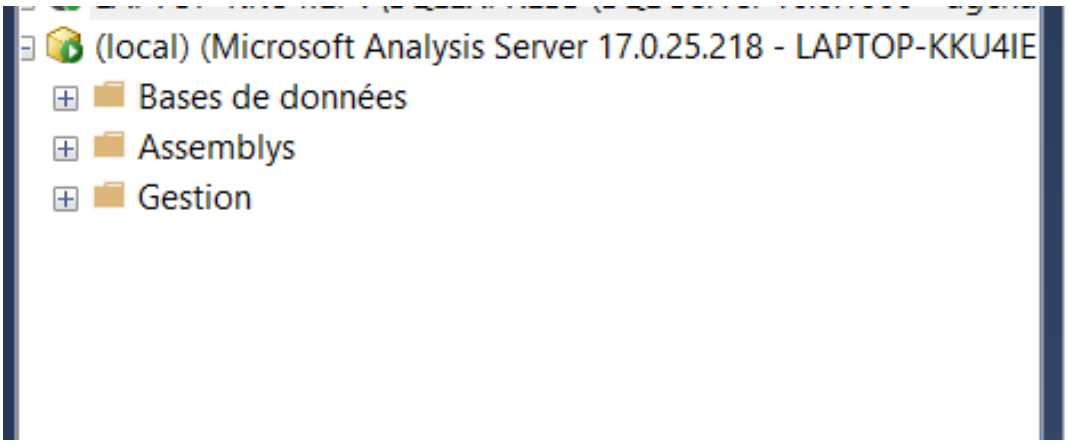


FIGURE 47 – Microsoft SQL Server Analysis Services

SQL Server Analysis Services est la plateforme dédiée à la conception et à l'analyse des cubes OLAP. Elle permet de définir les mesures, les dimensions, les hiérarchies et les agrégations afin d'optimiser les performances. SSAS transforme les données relationnelles en un modèle multidimensionnel, facilitant ainsi l'exploration et l'analyse décisionnelle.

10 Création du cube OLAP

10.1 Création du projet Analysis Services

La création du cube OLAP débute par la mise en place d'un projet multidimensionnel sous Visual Studio. Les principales étapes sont les suivantes :

1. Création d'un projet **Analysis Services Multidimensionnel et Data Mining**

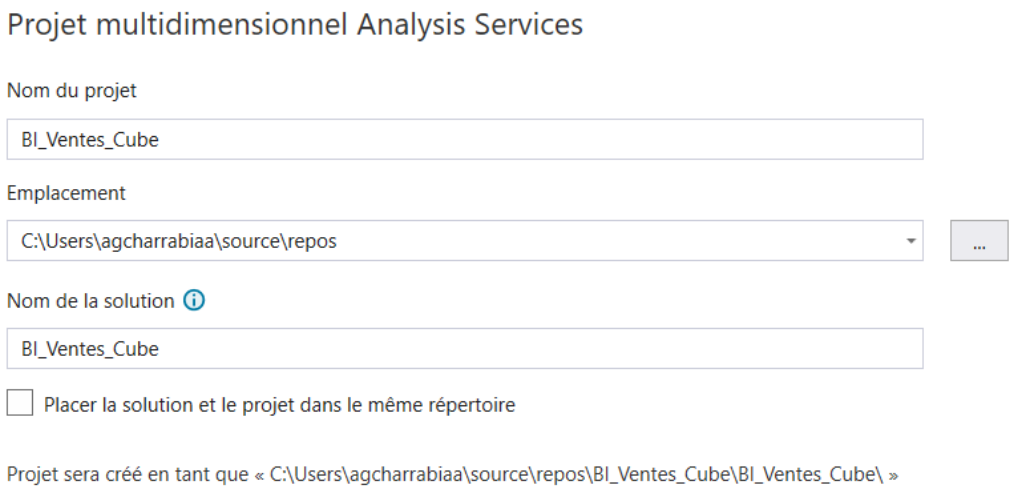


FIGURE 48 – Création du projet BI *Ventes_Cube*

2. Création de la source de données La source de données correspond à la connexion vers la base **ComptoirDWH** hébergée sur SQL Server.

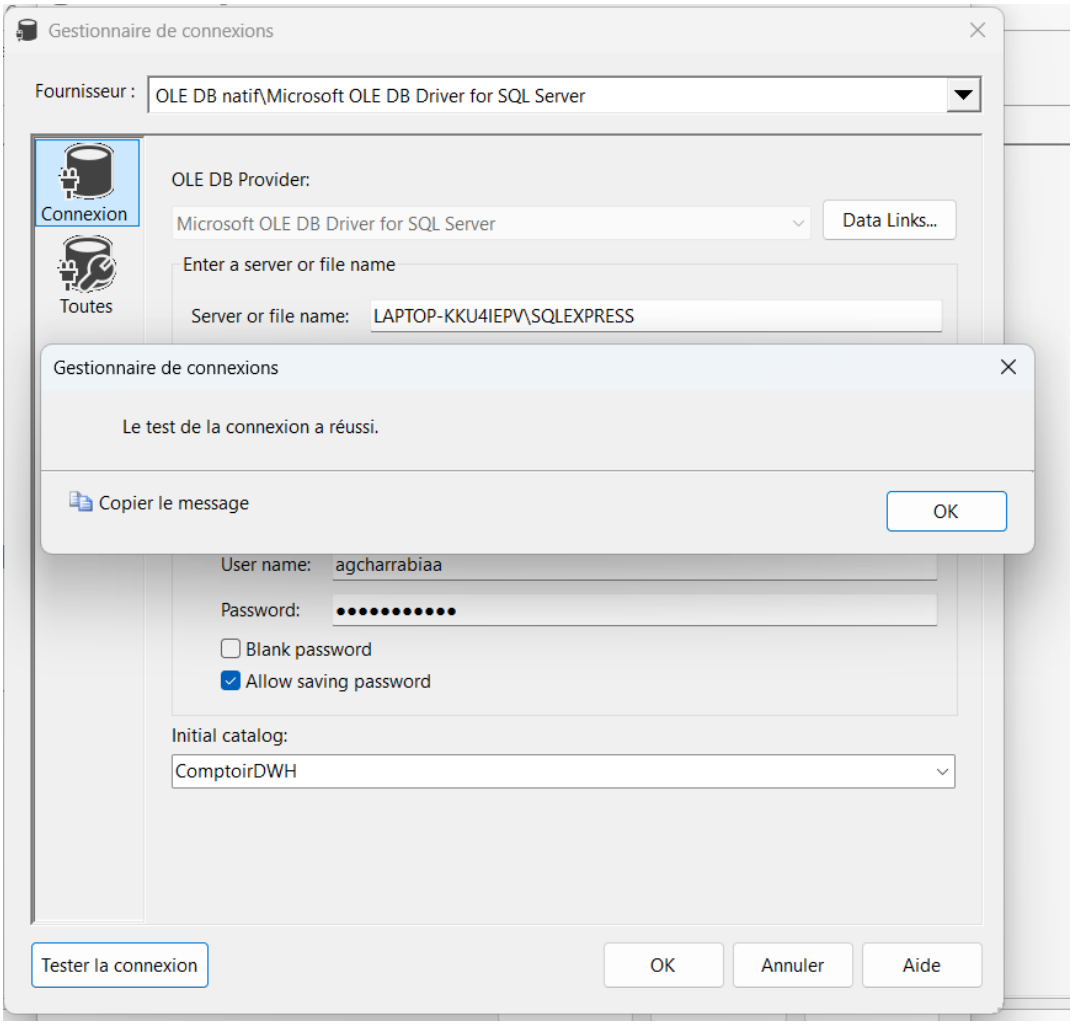


FIGURE 49 – Création de la source de données SQL Server

3. Création de la vue de source de données (Data Source View – DSV) La DSV permet de sélectionner les tables nécessaires à la construction du cube et de définir les relations entre elles.

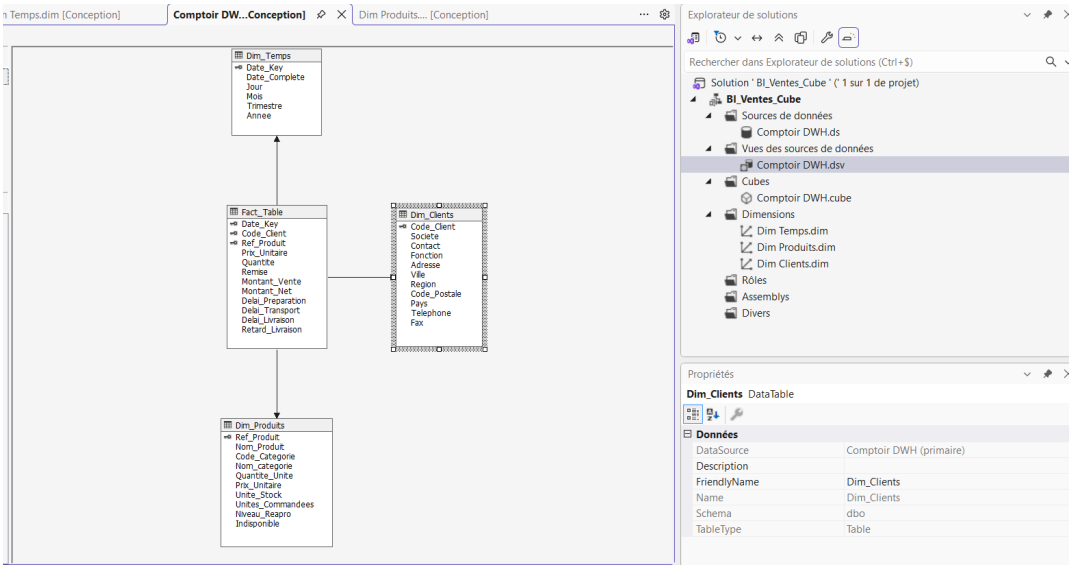


FIGURE 50 – Création de la Data Source View

4. Création du cube OLAP Le cube OLAP constitue l'élément central du projet SSAS. Il permet d'analyser les données à travers des mesures et des dimensions.

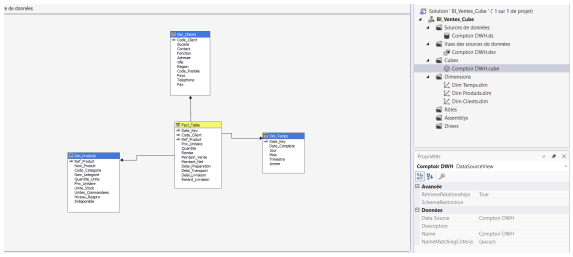


FIGURE 51 – Cube OLAP

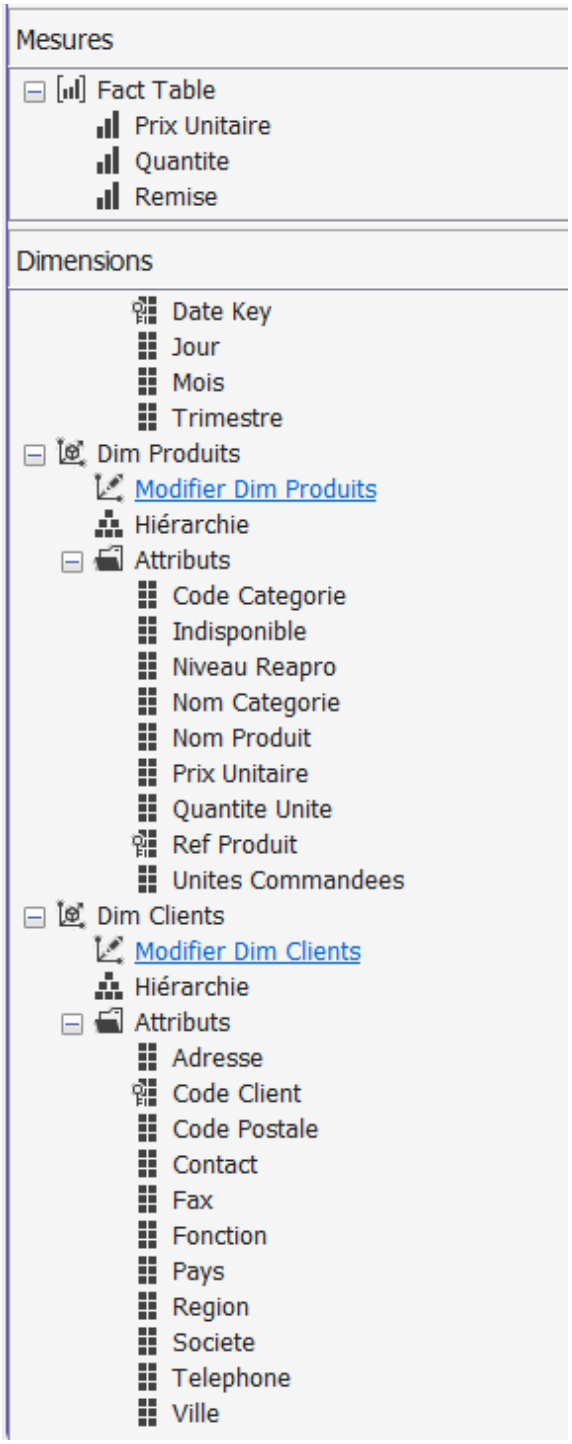


FIGURE 52 – Structure du cube OLAP

11 Déploiement et traitement du cube OLAP

11.1 Configuration du déploiement

Avant le déploiement du cube, il est nécessaire de configurer le serveur cible ainsi que le nom de la base de données **Analysis Services**. Cette étape garantit une installation correcte du cube sur le serveur décisionnel.

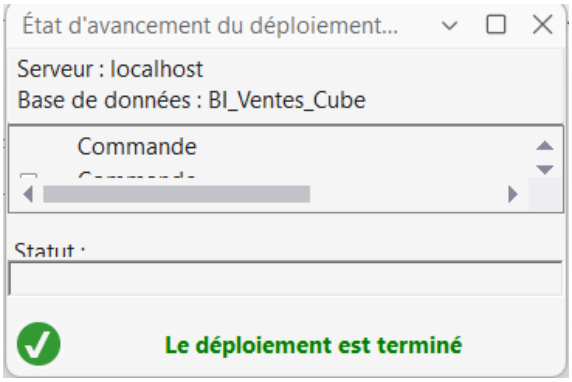


FIGURE 53 – Configuration du déploiement du cube

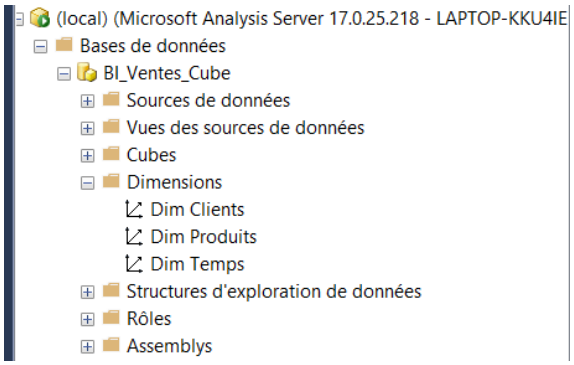


FIGURE 54 – Résultat du déploiement

11.2 Traitement du cube OLAP

Le traitement du cube OLAP consiste à charger les données depuis la base source vers le cube multi-dimensionnel. Cette étape permet de rendre les données disponibles pour l'analyse et l'exploration via des requêtes OLAP.

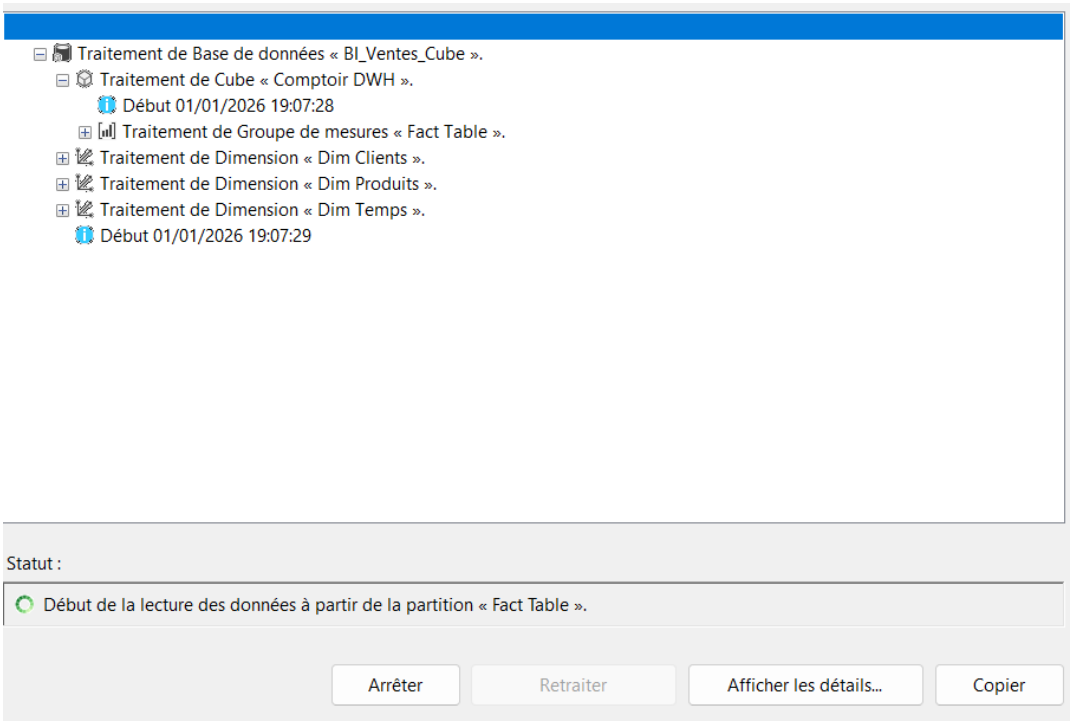


FIGURE 55 – Traitement du cube OLAP

Conclusion

Au terme de ce chapitre, nous avons présenté les différentes étapes ayant conduit à la conception et à la mise en œuvre du cube OLAP dans le cadre du projet décisionnel basé sur **ComptoirDB**. Après la définition de la table de faits et des dimensions, les données ont été organisées sous forme multidimensionnelle afin de permettre une analyse flexible et performante.

L'utilisation de **Microsoft SQL Server**, **Visual Studio** et **SQL Server Analysis Services** a permis de construire un environnement fiable et adapté aux besoins décisionnels. Le cube OLAP réalisé constitue ainsi une base solide pour les analyses avancées, le reporting et l'application des techniques de Data Mining.

Analyse et Visualisation avec Power

Introduction

L'analyse et la visualisation représentent l'étape finale et essentielle du projet de Business Intelligence et Data Mining basé sur ComptoirDB. Bien que les phases de modélisation, d'ETL et de stockage des données soient fondamentales, c'est à travers les outils de visualisation que les données deviennent réellement exploitables.

L'utilisation d'outils décisionnels tels que Power BI permet de transformer les données transactionnelles en tableaux de bord clairs et interactifs, facilitant l'analyse des indicateurs clés comme les ventes, les délais de livraison et la performance des clients. Cette étape soutient ainsi une prise de décision rapide et éclairée.

12 Technologies Utilisées



FIGURE 56 – Power BI

Power BI est un outil de Business Intelligence de Microsoft qui permet de visualiser et d'analyser des données issues de sources variées. Il facilite l'exploration des données du Data Warehouse à travers des tableaux de bord interactifs et des rapports dynamiques.

13 Chargement des Données dans Power BI

D'abord, les données transformées issues du ComptoirDWH Microsoft SQL SERVER sont importées dans Power BI via une connexion directe.

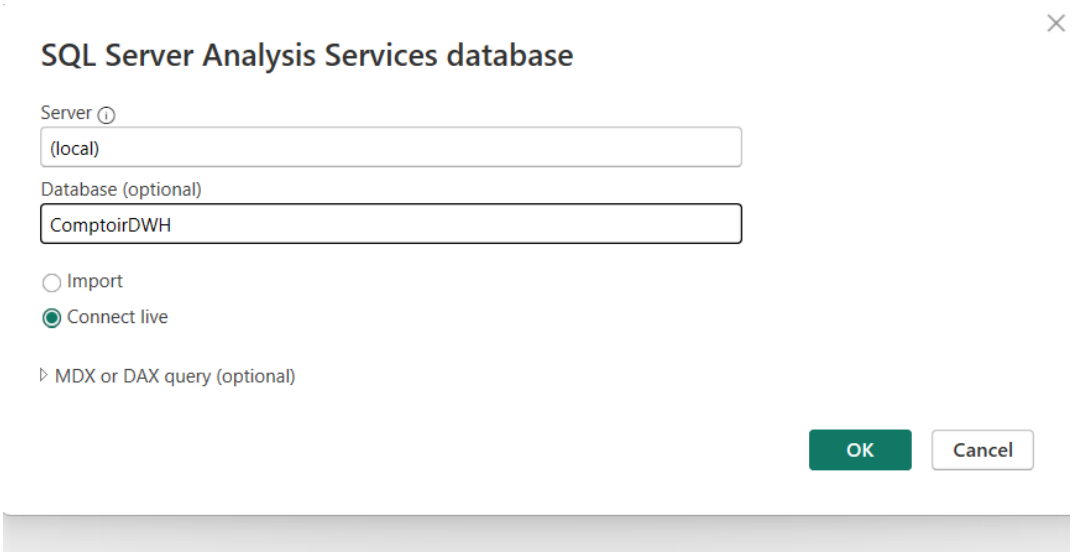
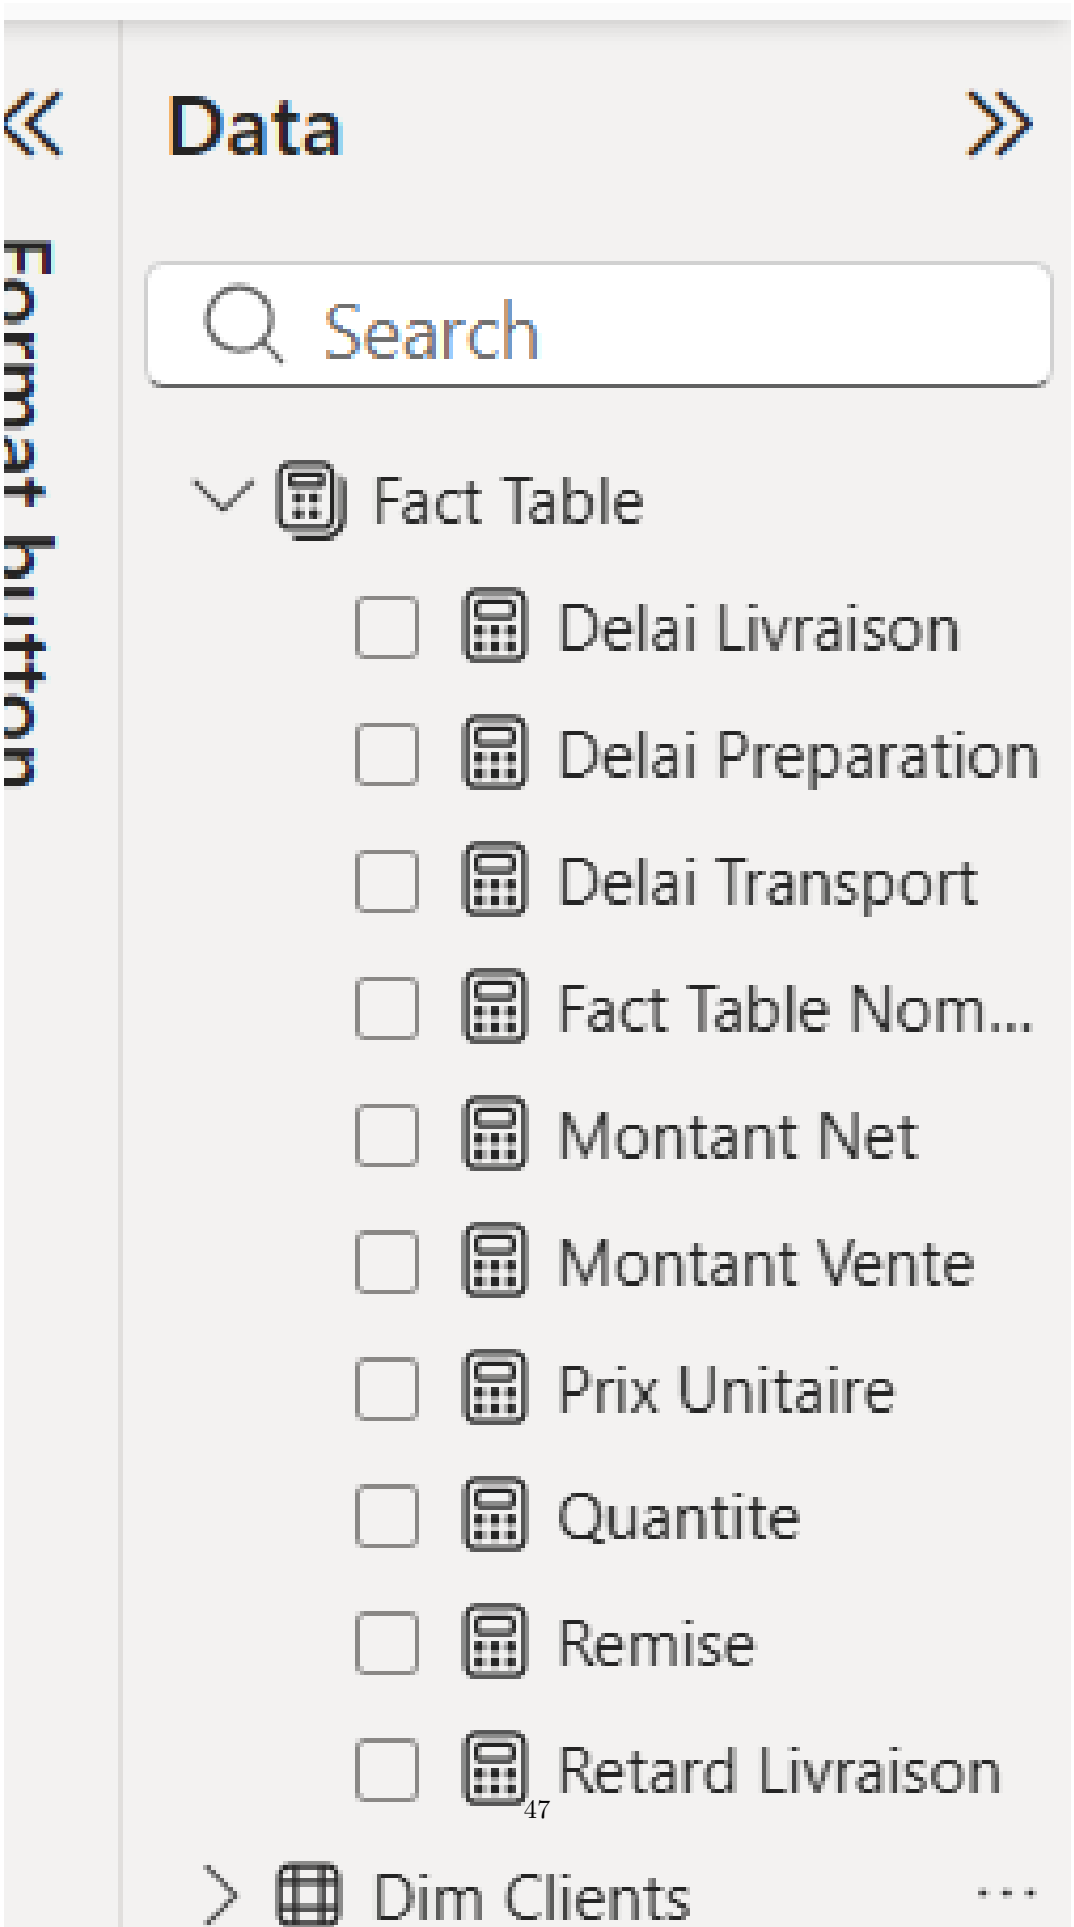


FIGURE 57 – Connexion au Power BI

Après avoir configuré la connexion avec les détails nécessaires (source de données, utilisateur et mot de passe), les tables de la base de données sont récupérées dans Power BI.


Data
Format button
Search
Fact Table
Delai Livraison
Delai Preparation
Delai Transport
Fact Table Nom...
Montant Net
Montant Vente
Prix Unitaire
Quantite
Remise
Retard Livraison
Dim Clients

14 Visualisation graphique

Le tableau de bord développé dans le cadre de ce projet BI basé sur la base de données ComptoirDB offre une vue synthétique et interactive des performances commerciales et logistiques de l'entreprise. Il permet aux décideurs de suivre en temps réel les principaux indicateurs de performance, tels que le chiffre d'affaires, le volume des ventes, le nombre de commandes, ainsi que les délais et retards de livraison.

Grâce à des visualisations dynamiques (graphiques, cartes et indicateurs), le tableau de bord facilite l'analyse des données selon différents axes, notamment le temps, les clients, les produits et les zones géographiques. Les filtres interactifs permettent d'explorer les données en profondeur et d'identifier rapidement les tendances, les anomalies et les écarts de performance.

Ce tableau de bord constitue ainsi un outil décisionnel efficace, contribuant à l'amélioration de la prise de décision stratégique et opérationnelle, tout en offrant une vision globale et détaillée de l'activité commerciale issue de ComptoirDB.

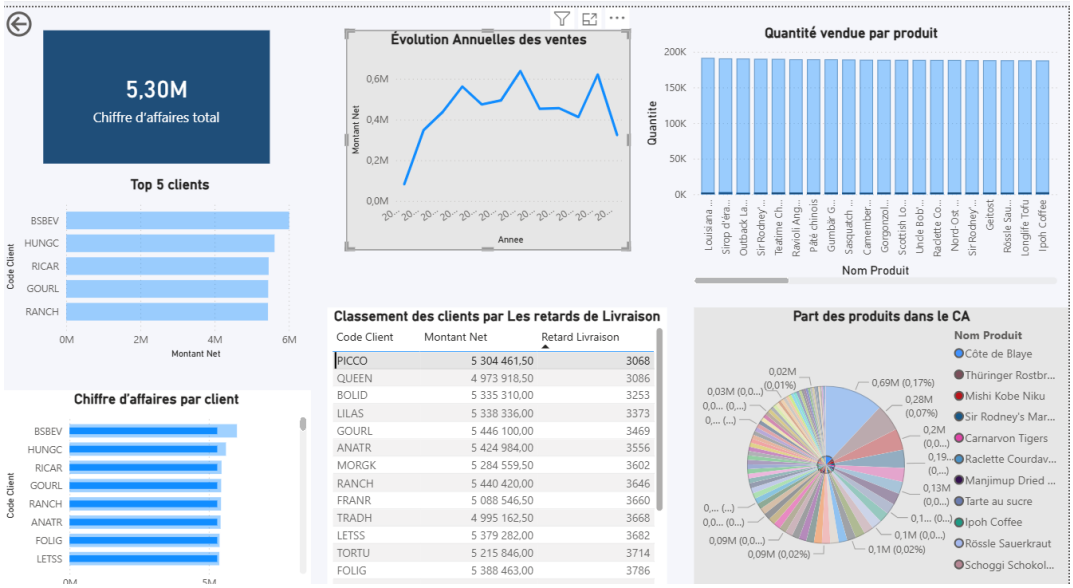


FIGURE 59 – Analyses et visualisations des résultats

description

Description des indicateurs et visualisations du tableau de bord

Carte KPI – Chiffre d'affaires total

Cette visualisation de type **KPI** présente le chiffre d'affaires global réalisé par l'entreprise sur la période analysée. La valeur affichée est de **5,30 millions**, offrant une vue synthétique et immédiate de la performance commerciale globale. Elle permet aux décideurs d'évaluer rapidement le niveau global des ventes et d'apprécier la santé financière de l'entreprise.

Graphique en courbe – Évolution annuelle des ventes

Ce graphique illustre l'**évolution du montant net des ventes par année**. L'analyse de la courbe met en évidence :

— une tendance globale à la hausse sur plusieurs années,

— des fluctuations traduisant des périodes de croissance et de baisse,

— des **pics de ventes** sur certaines années, parfois suivis d'un léger recul.

Cette visualisation permet d'analyser la **dynamique temporelle des ventes** et d'identifier les années les plus performantes.

Histogramme – Quantité vendue par produit

Cet histogramme en barres verticales représente la **quantité totale vendue pour chaque produit**. Les produits sont affichés sur l'axe horizontal, tandis que les quantités vendues figurent sur l'axe vertical.

Il permet notamment de :

— comparer les performances des différents produits,

— identifier les **produits les plus demandés**,

— repérer les produits à faible rotation.

Histogramme horizontal – Top 5 clients

Ce graphique présente les **cinq clients générant le plus de chiffre d'affaires**. Chaque barre correspond à un client, et sa longueur représente le **montant net des ventes générées**.

Il met en évidence :

— les clients stratégiques pour l'entreprise,

— la concentration du chiffre d'affaires sur un nombre restreint de clients.

Histogramme horizontal – Chiffre d'affaires par client

Cette visualisation montre le **chiffre d'affaires généré par chaque client**. Elle offre une vision détaillée de la contribution individuelle des clients au chiffre d'affaires total.

Ce graphique est particulièrement utile pour :

— analyser la **répartition des ventes**,

— identifier les clients à fort potentiel,

— mettre en place des stratégies de fidélisation adaptées.

Tableau – Classement des clients par retards de livraison

Ce tableau présente les informations suivantes :

— le **code client**,

— le **montant net des ventes**,

— le **retard cumulé de livraison**.

Il permet de :

— identifier les clients les plus impactés par les retards de livraison,

— analyser la relation entre chiffre d'affaires et performance logistique,

— soutenir la prise de décision visant à améliorer la chaîne de livraison.

Intégration du DataMining

15 Description des données

Dans cette partie, les données utilisées contiennent pour chaque client la moyenne des retards ainsi que le retard maximal enregistré. Cette information permet d'identifier les clients les plus ponctuels et ceux qui présentent un risque élevé de retard.

16 Prétraitement

Les transactions textuelles ont été transformées en une représentation booléenne (True/False) afin de permettre l'application de l'algorithme K-means. Cette transformation conserve l'information de présence ou d'absence d'un item dans chaque transaction, tout en rendant les données exploitables pour l'algorithme.

FIGURE 60 – Dataset chargé dans WEKA

17 Méthodologie

17.1 Outil WEKA

WEKA est un outil de data mining permettant l'application de plusieurs algorithmes de clustering et de classification.

17.2 Algorithme K-means

L'algorithme K-means vise à partitionner les données en K groupes homogènes en minimisant la distance entre les instances et les centroïdes.

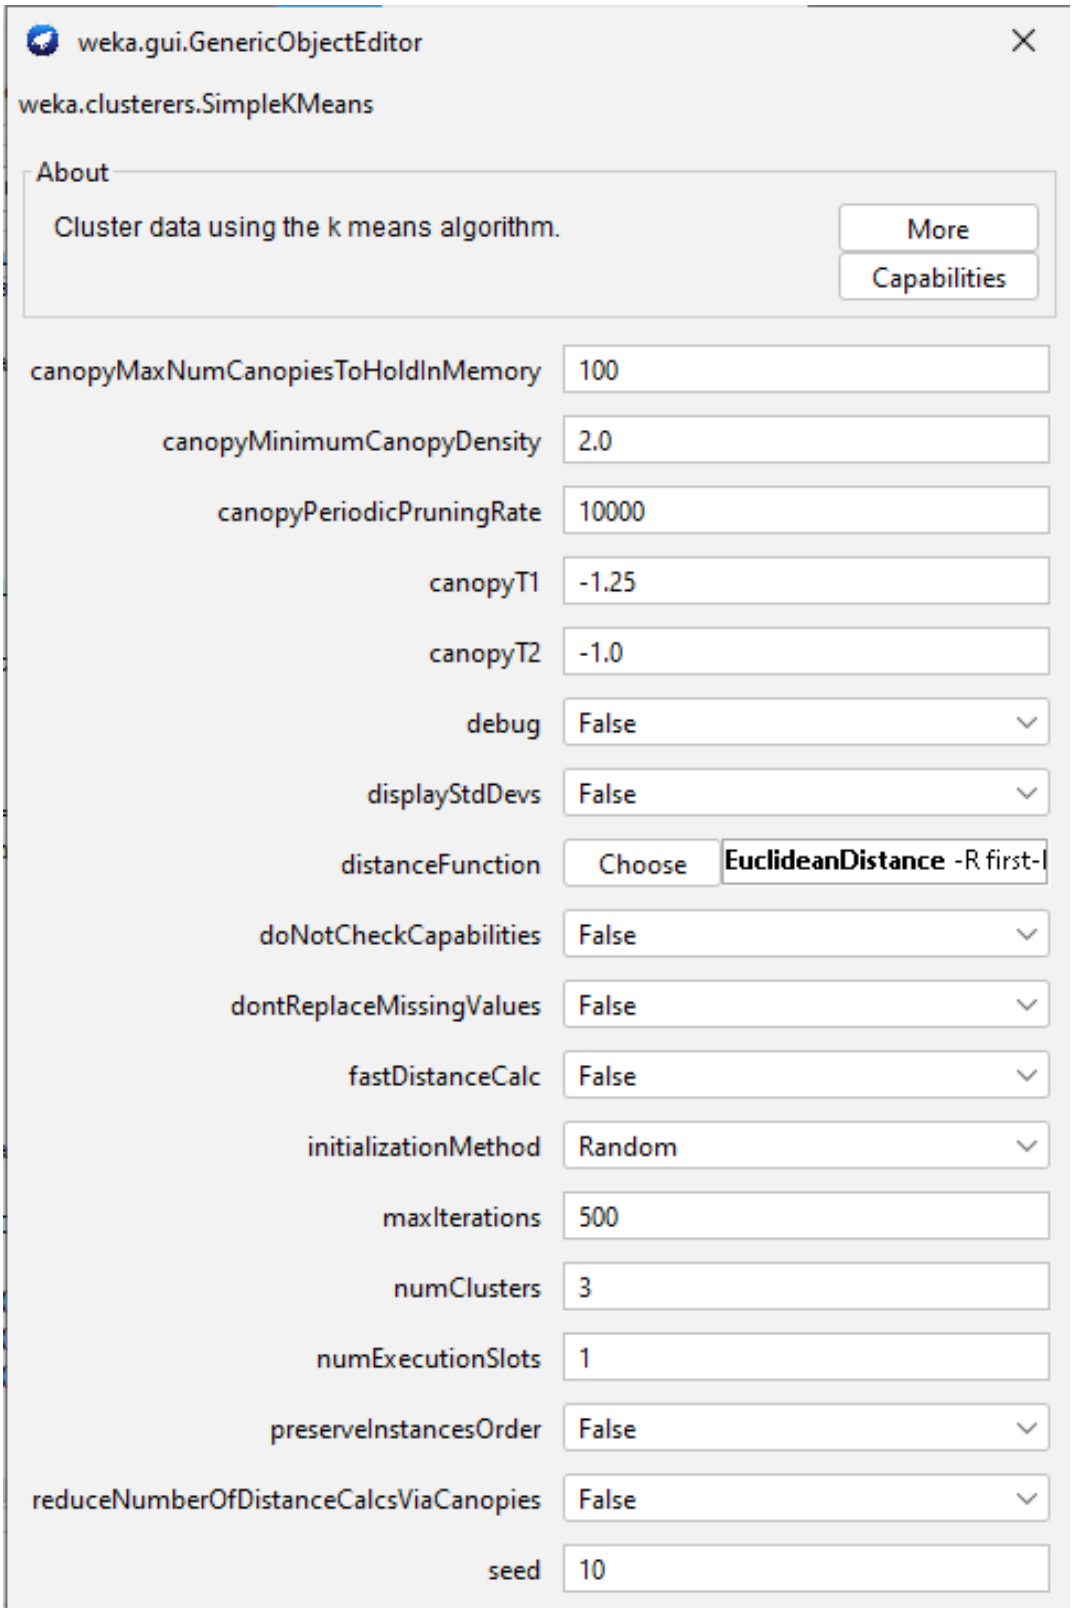
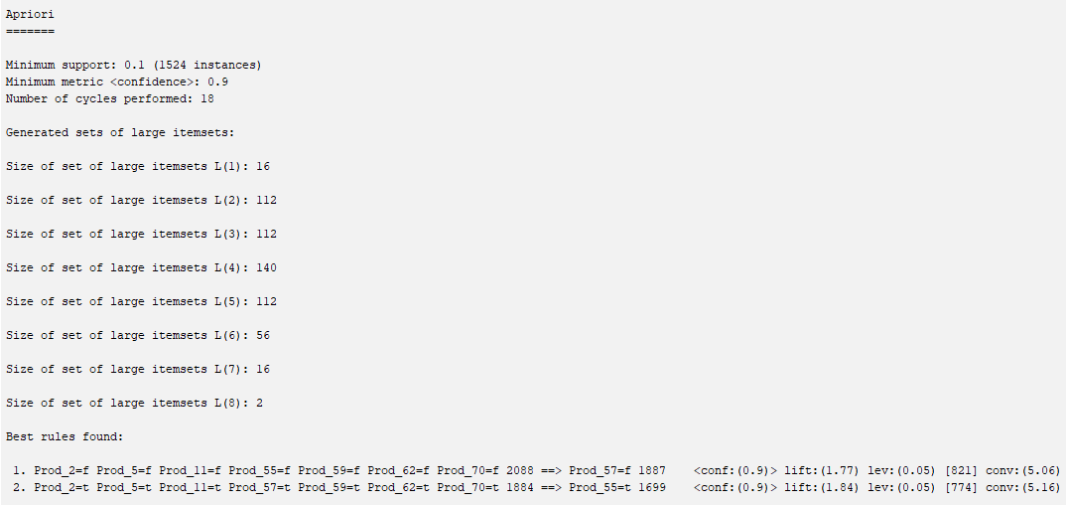


FIGURE 61 – Configuration de l'algorithme K-means

17.3 Algorithme Apriori

L'algorithme Apriori permet d'extraire des règles d'association fréquentes à partir des transactions. Il identifie les items souvent achetés ensemble et génère des règles du type "Si A et B, alors C", avec un seuil de support et de confiance définis par l'utilisateur. Cette analyse permet de mieux comprendre les relations entre les produits et d'optimiser les recommandations ou le merchandising.



```
Apriori
=======

Minimum support: 0.1 (1524 instances)
Minimum metric <confidence>: 0.9
Number of cycles performed: 18

Generated sets of large itemsets:

Size of set of large itemsets L(1): 16

Size of set of large itemsets L(2): 112

Size of set of large itemsets L(3): 112

Size of set of large itemsets L(4): 140

Size of set of large itemsets L(5): 112

Size of set of large itemsets L(6): 56

Size of set of large itemsets L(7): 16

Size of set of large itemsets L(8): 2

Best rules found:

 1. Prod_2=f Prod_5=f Prod_11=f Prod_55=f Prod_59=f Prod_62=f Prod_70=f 2088 ==> Prod_57=f 1887    <conf:(0.9)> lift:(1.77) lev:(0.05) [821] conv:(5.06)
 2. Prod_2=t Prod_5=t Prod_11=t Prod_57=t Prod_59=t Prod_62=t Prod_70=t 1884 ==> Prod_55=t 1699    <conf:(0.9)> lift:(1.84) lev:(0.05) [774] conv:(5.16)
```

FIGURE 62 – Règles d'association générées par Apriori dans WEKA

18 Résultats et Analyse

18.1 Résultats obtenus

```
Initial starting points (random):

Cluster 0: 19,57
Cluster 1: 19,54
Cluster 2: 16,56

Missing values globally replaced with mean/mode

Final cluster centroids:
                            Cluster#
Attribute      Full Data          0          1          2
                  (87.0)     (35.0)     (20.0)     (32.0)
=============================================================
delai_moyen       18.023    18.9429      18.55    16.6875
delai_max        55.4368    57.2857      52.45    55.2813




Time taken to build model (full training data) : 0 seconds

=== Model and evaluation on training set ===

Clustered Instances

0      35 ( 40%)
1      20 ( 23%)
2      32 ( 37%)
```

FIGURE 63 – Résultats du clustering sous WEKA

18.2 Interprétation

Chaque cluster regroupe des transactions présentant des caractéristiques similaires, ce qui permet une meilleure compréhension de la structure des données.

Conclusion Générale

Ce projet de Business Intelligence et Data Mining, basé sur la base de données ComptoirDB, a permis de transformer des données transactionnelles en informations décisionnelles pertinentes. À travers les phases de modélisation multidimensionnelle, de traitement ETL et d'analyse, une architecture BI cohérente a été mise en place afin d'exploiter efficacement les données.

Les tableaux de bord réalisés ont facilité le suivi des indicateurs clés de performance, tandis que l'application des techniques de Data Mining a contribué à l'identification de tendances et de comportements significatifs. Ainsi, ce projet met en évidence l'apport essentiel de la BI et du Data Mining dans l'amélioration de la prise de décision stratégique et opérationnelle, tout en ouvrant des perspectives d'évolution futures.